



Adam Banuszewicz

nr albumu: 33816

kierunek studiów: Teleinformatyka

forma studiów: studia stacjonarne

specjalność: Sieci teleinformatyczne i systemy mobilne

**ALGORYTMY POLECEŃ MENTALNYCH W INTERFEJSACH
MÓZG-KOMPUTER**

**ALGORITHMS OF MENTAL COMMANDS IN BRAIN-COMPUTER
INTERFACES**

Praca dyplomowa magisterska

napisana pod kierunkiem:

dr. inż. Roberta Krupińskiego

Katedra Przetwarzania Sygnałów i Inżynierii Multimedialnej

Data wydania tematu pracy: 01.11.2018 r.

Data złożenia pracy: TODO r.

Szczecin, TODO

OŚWIADCZENIE AUTORA PRACY DYPLOMOWEJ

Oświadczam, że praca magisterska pn.
„Algorytmy poleceń mentalnych w interfejsach mózg–komputer”
napisana pod kierunkiem:
dr. inż. Roberta Krupińskiego
jest w całości moim samodzielnym autorskim opracowaniem sporządzonym przy wykorzystaniu wykazanej w pracy literatury przedmiotu i materiałów źródłowych.
Złożona w dziekanacie Wydziału Elektrycznego treść mojej pracy dyplomowej w formie elektronicznej jest zgodna z treścią w formie pisemnej.

Oświadczam ponadto, że złożona w dziekanacie praca dyplomowa ani jej fragmenty nie były wcześniej przedmiotem procedur procesu dyplomowania związanych z uzyskaniem tytułu zawodowego w uczelniach wyższych.

.....
podpis dyplomanta

Szczecin, dn. TODO r.

Streszczenie pracy

TODO

Słowa kluczowe

BCI, Elektroencefalografia

Abstract

TODO

Keywords

BCI, Electroencephalography

Spis treści

Wykaz ważniejszych oznaczeń i skrótów	7
Wprowadzenie	8
1. Wstęp do tematyki interfejsów mózg–komputer	9
1.1. Czym jest oraz jak działa interfejs mózg–komputer	9
1.2. Rodzaje interfejsów mózg–komputer	11
1.2.1. Interfejsy inwazyjne	11
1.2.2. Interfejsy nieinwazyjne	12
1.2.3. Inne rodzaje interfejsów	13
1.3. Przetwarzanie sygnałów	15
1.3.1. Usunięcie szumów	15
1.3.2. Ekstrakcja cech	17
1.3.3. Klasyfikacja sygnałów	18
1.4. Przegląd potencjalnych zastosowań	20
1.4.1. Interfejs komunikacyjny	20
1.4.2. Sterowanie wózkiem inwalidzkim	21
1.4.3. Rehabilitacja	21
1.4.4. Nadzór skupienia	22
1.4.5. Gry komputerowe	23
2. Charakterystyka wybranych urządzeń komercyjnych	25
2.1. Emotiv Insight	25
2.2. Emotiv EPOC+	27
2.3. Muse/Muse 2	29
2.4. MindWave Mobile 2	31
2.5. OpenBCI Ultracortex Mark IV	33
3. Projekt wirtualnej klawiatury	39
3.1. Założenia projektowe	39
3.2. Wybór narzędzi	39
3.2.1. Urządzenia rejestrujące	39
3.2.2. Język programowania	40
3.2.3. Środowisko programistyczne	41
3.2.4. System kontroli wersji	42
3.3. Omówienie aplikacji	42
3.3.1. Struktura kodu źródłowego	42
3.3.2. Algorytm działania	44
3.3.3. Trening detekcji komend mentalnych	44
3.3.4. Komunikacja z urządzeniem	45
3.3.5. Proces decyzyjny	45
3.4. Omówienie interfejsu użytkownika	45
3.4.1. Zakładka <i>Virtual Keyboard</i>	45
3.4.2. Zakładka <i>Messenger</i>	45
3.4.3. Zakładka <i>About</i>	45

3.4.4. Zakładka <i>Connection</i>	45
3.4.5. Zakładka <i>Settings</i>	45
4. Badania opracowanego systemu	47
4.1. Badanie wpływu zakłóceń	47
4.2. Badanie wpływu parametrów algorytmu	47
Zakończenie	48
Bibliografia	49
Spis tabel	53
Spis rysunków	54
Spis kodów źródłowych	55

Wykaz ważniejszych oznaczeń i skrótów

API	Application programming interface — Interfejs programistyczny aplikacji
BCI	Brain-computer interface — Interfejs mózg-komputer
EEG	Elektroencefalografia
EKG	Elektrokardiografia
EMG	Elektromiografia
EOG	Elektrookulografia
SDK	Software development kit — Zestaw narzędzi do tworzenia oprogramowania

Wprowadzenie

TODO

Cel pracy

TODO

Zakres pracy

TODO

ROZDZIAŁ 1

Wstęp do tematyki interfejsów mózg–komputer

1.1. Czym jest oraz jak działa interfejs mózg–komputer

Interfejs mózg–komputer (ang. BCI – brain–computer interface) jest układem, który przekształca aktywność ośrodkowego układu nerwowego w polecenia dla zewnętrznego urządzenia wykonawczego. BCI pracuje w zamkniętej pętli, w której można wyróżnić sześć etapów: (1) rejestrację aktywności mózgu, (2) usunięcie szumów, (3) ekstrakcję cech, (4) klasyfikację sygnałów, (5) wydanie polecenia oraz (6) sprzężenie zwrotne[7]. Taka definicja prowadzi do konkluzji, iż interfejs mózg–komputer stwarza dodatkowy efektor dla układu nerwowego[47].

Jak wcześniej wspomniano, BCI przekształca sygnały pozyskane z ośrodkowego układu nerwowego (ang. CNS – central nervous system), który razem z obwodowym układem nerwowym (ang. PNS – peripheral nervous system) składa się na układ nerwowy człowieka.

W skład PNS wchodzi układ somatyczny, który stanowi połączenie z narządami zmysłu, mięśniami szkieletowymi i skórą, oraz układ autonomiczny, który unerwia narządy wewnętrzne, przez co zapewnia reakcje niezależne od woli, na przykład bicie serca i oddychanie[43].

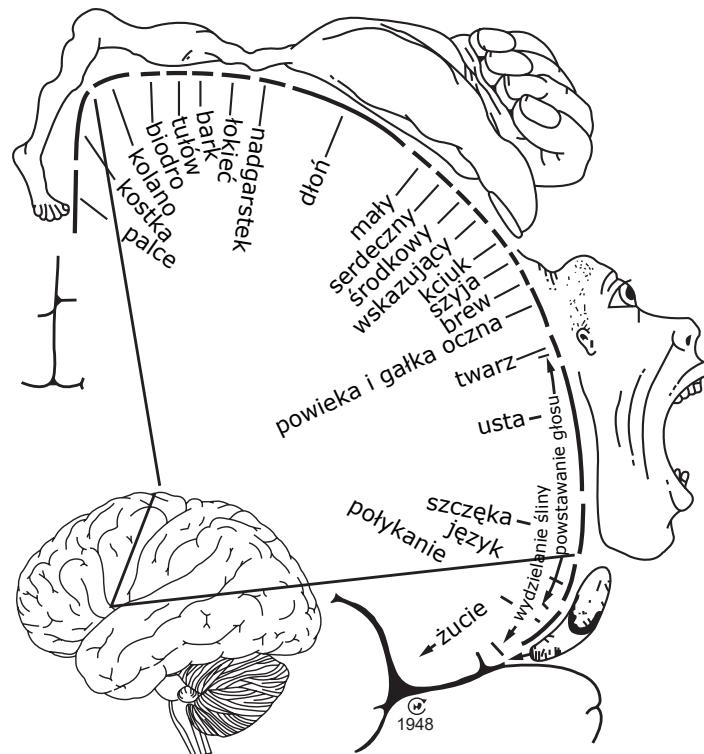
CNS składa się z mózgowia oraz rdzenia kręgowego. Rdzeń kręgowy przewodzi impulsy nerwowe pomiędzy mózgiem a obwodowym układem nerwowym. Neurony w rdzeniu kręgowym tworzą również lokalne pętle sprzężenia zwrotnego, które odpowiadają za odruchy bezwarunkowe[43]. Mózgowie odpowiada za kontrolę działań, samoregulację procesów biologicznych oraz funkcje poznawcze, takie jak na przykład uczenie się oraz pamięć.

Wspomniana w sformułowanej definicji aktywność CNS obejmuje zjawiska elektrofizjologiczne, neurochemiczne oraz metaboliczne, które mogą być rejestrowane przez monitorowanie pola elektrycznego, magnetycznego albo innych parametrów za pomocą czujników na skórze głowy, powierzchni mózgu lub wewnątrz mózgu[47]; charakter rejestrowanych parametrów zależy od przyjętej koncepcji realizacji BCI.

Większość współczesnych interfejsów mózg–komputer działa w oparciu o potencjały wywołane[6, 18]. Inną często wykorzystywaną metodą jest detekcja wyobrażenia ruchu[18].

Potencjały wywołane (ang. ERP – event-related potentials) są odpowiedzią na bodźce poznawcze, czuciowe lub ruchowe[6]. Wymagają one zewnętrznej stymulacji, która może być na przykład słuchowa lub wzrokowa. Przykładem może być BCI oparte o potencjały P300, które zostało omówione w rozdziale 1.4.1 na stronie 20. Inną metodą jest wykorzystanie wzrokowych potencjałów wywołanych stanu ustalonego (ang. SSVEP – steady-state visual evoked potentials). W tym podejściu każda komenda jest podświetlana ze stałą, unikalną częstotliwością[18]. W aktywności CNS użytkownika skupiającego się na komendzie o danej częstotliwości możliwe będzie zaobserwowanie SSVEP o takiej samej częstotliwości.

Wyobrażenia ruchu powodują zmiany w rytmach sensoromotorycznych (ang. SMR – sensorimotor rhythms), rejestrowane w obszarach odpowiedzialnych za czucie oraz motorykę[18]. Zmiana jest szczególnie widoczna w paśmie mu (8÷12 Hz) oraz beta (13÷30 Hz)[43]. Jest to tak zwana desynchronizacja/synchronizacja wywołana (ang. ERD/ERS – event-related desynchronization/synchronization), czyli kolejno spadek oraz wzrost mocy w rzeczonych pasmach. Na podstawie *map neurologicznych*, takich jak na przykład przedstawiona na rysunku 1.1, możliwe jest określenie części ciała, której wyobrażenie ruchu spowodowało aktywność neuronów w danym miejscu mózgu.



Rysunek 1.1. Homunculus ruchowy Penfielda; mapa kory mózgu odzwierciedlająca ośrodki ruchowe

Źródło: [47]

1.2. Rodzaje interfejsów mózg–komputer

1.2.1. Interfejsy inwazyjne

Interfejsy pozwalające na pozyskiwanie sygnałów bezpośrednio z komórek mózgowych nazywane są inwazyjnymi. Technika ta stosowana jest najczęściej w badaniach przeprowadzanych z wykorzystaniem zwierząt[43]. U ludzi pomiary inwazyjne pobierane są zazwyczaj w warunkach klinicznych, podczas operacji mózgu lub monitorowania pacjenta bezpośrednio przed lub po operacji.

Umieszczenie inwazyjnego BCI wymaga skomplikowanej operacji neurochirurgicznej, w której część czaszki jest usuwana, elektroda lub implant jest umieszczany w mózgu, a następnie kość jest przytwierdzana z powrotem[43]. Operacja obarczona jest ryzykiem uszkodzenia tkanki oraz w konsekwencji połączeń pomiędzy neuronami[18].

Interfejsy inwazyjne charakteryzują się najwyższą jakością pozyskanych sygnałów. Spowodowane jest to wyeliminowaniem problemów związanych z niską przewodnością czaszki¹ oraz zredukowaniem artefaktów poprzez zapewnienie dodatkowej warstwy filtrującej sygnały. Inną zaletą jest możliwość ich pozycjonowania bezpośrednio w płatach istotnych z perspektywy konkretnego zastosowania, na przykład w obszarach odpowiedzialnych za funkcje ruchowe lub emocje.

Do inwazyjnej akwizycji sygnałów wykorzystywane są:

Mikroelektrody — zostały opracowane do akwizycji sygnałów oraz stymulacji mózgu.

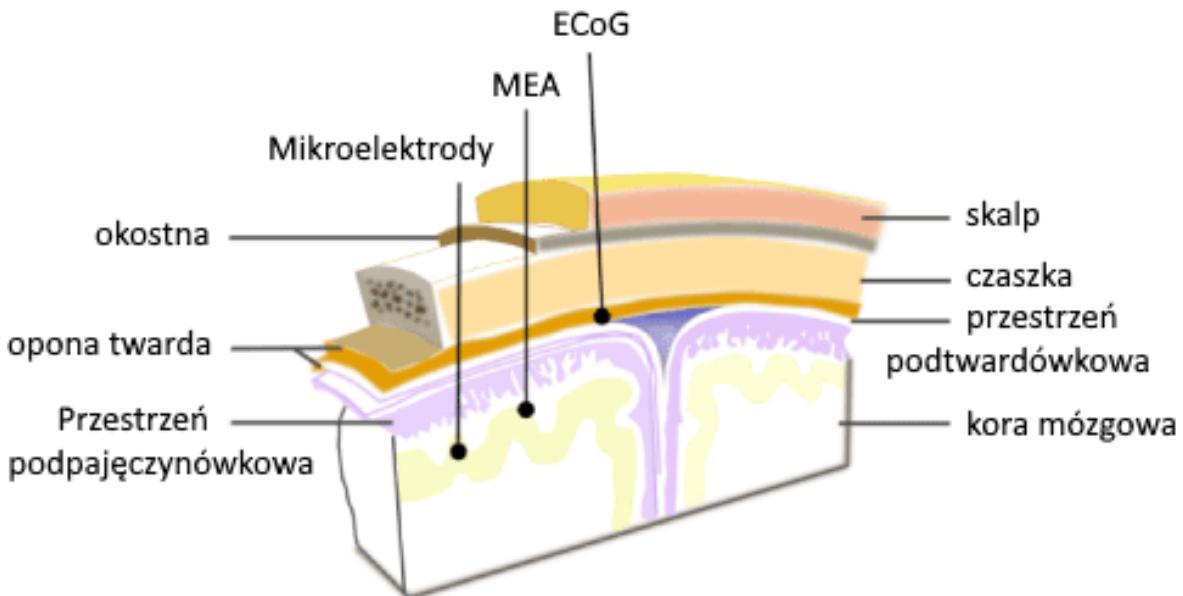
Przenikając oponę miękką oraz korę mózgową, umieszczone są w odległości około 150 µm od docelowego neuronu[1]. Są w stanie rejestrować aktywność na poziomie pojedynczych neuronów.

MEA — układy mikroelektrod (ang. multielectrode array, również microelectrode array) umieszczanych w korze mózgowej. Są pozycjonowane w pobliżu docelowej populacji neuronów. Odległości między poszczególnymi elektrodami są różne w zależności od realizacji i wynoszą przykładowo 400 µm dla układów Utah oraz 100 µm dla układów Michigan[17]. Ze względu na sposób wykonania wśród głównych typów mikroelektrod można wyróżnić tak zwane *microwire arrays*, *micro-machined arrays* oraz *flexible arrays*[17]. Więcej na temat MEA można znaleźć w literaturze [1, 17, 47].

ECoG — elektrokortykografia (ang. electrocorticography), czasem nazywana iEEG (ang. intracranial electroencephalogram – wewnętrzczaszkowa elektroencefalografia), jest wykonywana przy użyciu elektrod umieszczonych w warstwie podtwardówkowej[1]. Jest wykorzystywana do rejestracji aktywności neuronalnej bez konieczności penetracji tkanki korowej. Jest najmniej inwazyjną metodą z omówionych w tym rozdziale, ponieważ nie ingeruje w strukturę opony miękkiej oraz kory mózgowej. Z racji umieszczenia bliżej kory charakteryzuje się wyższą amplitudą rejestrowanych sygnałów, szerszym zakresem ich częstotliwości oraz lepszymi parametrami topograficznymi niż zewnętrzczaszkowe badanie EEG[18].

¹Przewodność czaszki jest około 20÷80 krotnie niższa niż mózgu[8]

Ich typowe umiejscowienie zostało pokazane na rysunku 1.2.



Rysunek 1.2. Umiejscowienie elektrod wykorzystywanych w inwazyjnych BCI w zależności od zastosowanej technologii

Źródło: [1]

Wprowadzenie na rynek inwazyjnych interfejsów mózg–komputer wymaga dalszych badań w zakresie ich wpływu na użytkownika podczas długotrwałego stosowania[18]. Ze względu na ich specjalistyczny charakter oraz skomplikowaną procedurę umieszczenia urządzenia, ich koszt będzie prawdopodobnie znacznie wyższy niż interfejsów nieinwazyjnych.

1.2.2. Interfejsy nieinwazyjne

Nieinwazyjne interfejsy mózg–komputer pozwalają na akwizycję sygnałów niewymagającą ingerencji w strukturę czaszki ani nawet skórę głowy. Technologie nieinwazyjne do estymacji sygnałów wykorzystują zmiany w ciśnieniu krwi lub fluktuacje pola elektrycznego oraz magnetycznego, spowodowane aktywnością neuronów w konkretnej części mózgu[43].

Trendem na przestrzeni ostatnich lat jest stosowanie interfejsów wykorzystujących EEG. Pomiary elektroencefalograficzne są niedrogim, wygodnym oraz uniwersalnym pod względem środowiska wykorzystania sposobem rejestracji aktywności mózgu, czego konsekwencją jest rozwój komercyjnych rozwiązań² oraz narastająca liczba publikacji naukowych w tym temacie. Z drugiej strony, interfejsy wykorzystujące MEG³ są kosztowne oraz niepraktyczne w codziennym użytkowaniu, przez co stanowią jedynie narzędzie badawcze dla technologii BCI[47].

²Przykłady dostępnych komercyjnie nieinwazyjnych interfejsów mózg–komputer wykorzystujących sygnały EEG zostały omówione w rozdziale 2.

³MEG (ang. magnetoencephalography) – magnetoencefalografia

Interfejsy nieinwazyjne są bardziej podatne na zakłócenia pochodzące ze środowiska z racji braku ekranowania elektrod czaszką, jak ma to miejsce w pomiarach inwazyjnych.

Jako nieinwazyjne sposoby rejestracji aktywności mózgu stosuje się:

EEG – badanie elektroencefalograficzne (ang. electroencephalography) jest rejestracją aktywności neuronów, które podczas swojej aktywacji wytwarzają potencjał elektryczny. W zależności od miejsca wzmożonej aktywności mózgu, możliwe jest określenie aktualnego stanu psychofizycznego użytkownika urządzenia. Amplitudy sygnałów EEG są zazwyczaj rzędu dziesiątek do setek mikrowoltów[1]. Badanie elektroencefalograficzne wykonuje się poprzez elektrody umieszczone na skalpie. Sensovery EEG są małe, lekkie oraz łatwe do założenia[1, 19].

MEG – badanie magnetoencefalograficzne (ang. magnetoencephalography) rejestruje zmiany pola magnetycznego wywołane przez prąd przepływający przez akson. Do pozyskiwania sygnałów wykorzystywane są bardzo czułe czujniki magnetyczne, na przykład SQUID (ang. superconducting quantum interference device), które są w stanie rejestrować pole magnetyczne rzędu $50\text{--}500 \text{ fT}^4$ [1]. Ta metoda pozyskiwania sygnałów wymaga specjalistycznych osłon przed zakłóceniami elektromagnetycznymi, co dyskwalifikuje możliwość jej użycia poza warunkami laboratoryjnymi.

MRI – obrazowanie metodą rezonansu magnetycznego (ang. magnetic resonance imaging) wykorzystuje rezonowanie płynów, głównie krwi, pod wpływem silnego pola magnetycznego[1]. W BCI wykorzystywane są jego dwie odmiany: fMRI oraz dMRI, kolejno funkcjonalne oraz dyfuzyjne MRI. Najczęściej stosowaną techniką rejestracji fMRI jest detekcja lokalnego natlenienia krwi BOLD (ang. blood oxygenation level dependent) podczas aktywacji neuronów przy użyciu ważonych sekwencji T2-zależnych[28].

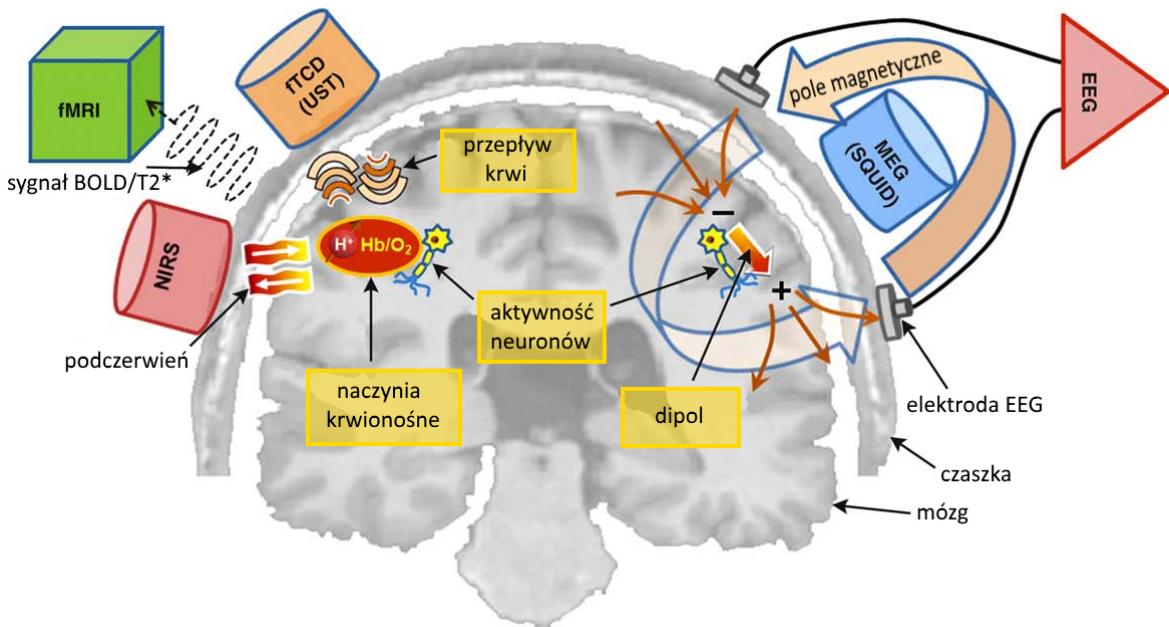
Literatura [28] wyszczególnia również metody NIRS oraz fTCD, jednak z racji ich małej popularności zostały pominięte w niniejszej pracy. Schematyczną zasadę działania poszczególnych interfejsów nieinwazyjnych przedstawiono na rysunku 1.3 na następnej stronie.

Nieinwazyjne interfejsy mózg–komputer są postrzegane jako najbezpieczniejsze oraz najtańsze BCI[19]. Należy mieć jednak na uwadze, że w tej gamie interfejsów istnieje znaczna rozpiętość cenowa, od około 200\$ za urządzenie w przypadku tych wykorzystujących EEG, do aż 2–3 milionów \$ w przypadku rejestratorów magnetoencefalograficznych[28].

1.2.3. Inne rodzaje interfejsów

Pomimo iż w literaturze dominuje klasyfikacja na interfejsy inwazyjne oraz nieinwazyjne, niektórzy autorzy definiują również inne rodzaje BCI. Wśród nich możemy wyróżnić interfejsy częściowo-inwazyjne, stymulujące oraz dwukierunkowe. Ponieważ nie znajdują one

⁴ $1 \text{ fT} = 1 \times 10^{-15} \text{ T}$; T – Tesla



Rysunek 1.3. Sposoby nieinwazyjnej akwizycji aktywności mózgu

Źródło: Opracowanie własne na podstawie [28]

zastosowania w niniejszej pracy oraz są w pewnym sensie pochodnymi omówionych rozdziałów, w celu dopełnienia tematu postanowiono zamieścić jedynie ich zwięzły opis oraz odniesienia do literatury, w której można uzyskać na ich temat więcej informacji.

Interfejsy częściowo-inwazyjne

W zależności od definicji inwazyjności, ten interfejs może zawierać się w interfejsach inwazyjnych, omówionych w rozdziale 1.2.1 na stronie 11. Rajesh P.N. Rao definiuje interfejsy częściowo-inwazyjne jako urządzenia, które nie ingerują w strukturę mózgu[43]. Autor niniejszej pracy nie zgadza się z taką klasyfikacją i postrzega jakakolwiek ingerencję w czaszkę jako przejaw inwazyjności.

Interfejsy częściowo-inwazyjne wykorzystują na przykład elektrokortykografię, czyli wewnętrznzczaszkową elektroencefalografię, lub sygnały pozyskane z nerwów znajdujących się poza mózgiem. W celu instalacji wymagają operacji, jednak nie wiąże się ona z penetracją mózgu. Ten typ interfejsów charakteryzuje się słabszymi parametrami sygnałów niż interfejsy inwazyjne, jednak posiada mniejsze ryzyko uszkodzenia mózgu[19].

Interfejsy częściowo-inwazyjne zostały poruszone w literaturze [18, 19, 43].

Interfejsy stymulujące

Interfejsy stymulujące pozwalają na przesyłanie informacji do mózgu. Możliwość stymulacji mózgu pozwala BCI na bezpośrednie przekazanie danych do mózgu[43], zapewniając tym samym swoisty dodatkowy zmysł. Stymulatory mogą być realizowane zarówno w technologii IBS (ang. invasive brain stimulation – inwazyjnej stymulacji mózgu) jak i NIBS (ang. non-invasive brain stimulation – nieinwazyjnej stymulacji mózgu).

Interfejsy stymulujące znajdują aktualnie zastosowanie przede wszystkim w medy-

cynie. Rozwiązania oparte o DBS (ang. deep brain stimulation – głęboką stymulację mózgu) są uznawaną metodą terapii między innymi w przypadku choroby Parkinsona oraz drżenia samoistnego. Przeprowadzane są również badania dotyczące przywrócenia zmysłu wzroku osobom niewidomym[43].

Interfejsy stymulujące zostały poruszone w literaturze [3, 16, 43].

Interfejsy dwukierunkowe

Dwukierunkowe interfejsy mózg–komputer, zwane również rekurencyjnymi, pozwalają na jednoczesne odczytywanie sygnałów z mózgu oraz przesyłanie do niego informacji. Są realizowane z wykorzystaniem dekodera, który tłumaczy aktywność neuronów na sygnały dla urządzenia wykonawczego, oraz enkodera, który dostarcza informacje z otoczenia bezpośrednio do mózgu, tworząc w ten sposób zamknięty układ sterowania[5].

Dzięki zastosowaniu interfejsów rekurencyjnych mózg nie musi polegać już wyłącznie na ciele w kwestii pozyskiwania sygnałów oraz wykonywania różnych czynności[43]. Jest to szczególnie istotne w odniesieniu do osób niepełnosprawnych, w których przypadku interfejsy te mogą zastąpić uszkodzone struktury organizmu.

Wyzwaniami stawianymi przed tym rodzajem interfejsów są[43]:

- opracowanie sposobu dostarczenia rozmaitych informacji do mózgu przez jego stymulację, rejestrując w tym samym czasie sygnały pochodzące zeń,
- utrzymanie komunikacji dwukierunkowej przez maksymalnie długi czas,
- uwzględnienie oraz wykorzystanie plastyczności mózgu, czyli możliwości do tworzenia nowych połączeń w celu adaptacji oraz w wyniku rozwoju.

Interfejsy dwukierunkowe zostały poruszone w literaturze [5, 43, 46].

1.3. Przetwarzanie sygnałów

1.3.1. Usunięcie szumów

Sygnały EEG charakteryzują się bardzo niskim współczynnikiem SNR⁵[19]. Z tego powodu przed przystąpieniem do ich analizy należy najpierw usunąć z nich możliwie największą ilość artefaktów. Przykładowe przebiegi zakłóceń zostały pokazane na rysunku 1.4 na stronie 17.

Pierwszym typem zakłóceń są zakłócenia pochodzące ze środowiska, w którym jest rejestrowany sygnał EEG. Można do nich zaliczyć między innymi zakłócenia od sieci energetycznej oraz elektroniki (komputerów, telefonów, routerów Wi-Fi i tym podobnych). Najprostszym sposobem minimalizacji ich wpływu na sygnał wyjściowy jest eliminacja źródeł zakłóceń – przeprowadzenie akwizycji sygnałów z dala od miast, usunięcie zbędnych urządzeń z otoczenia, zastąpienie, o ile to możliwe, zasilania niezbędnych urządzeń prądem przemiennym na rzecz prądu stałego. Innym sposobem jest wykorzystanie klatki Faradaya.

⁵SNR (ang. signal-to-noise ratio) – stosunek sygnału do szumu

Drugim typem zakłóceń są tak zwane zakłócenia fizjologiczne. Powstają one na skutek ruchu ciała lub innych fluktuacji potencjałów bioelektrycznych. Ich źródła są niemożliwe do wyeliminowania. Typowymi przykładami takich zakłóceń są sygnały EOG, EMG oraz EKG. W szczególności dwa pierwsze, z racji małej odległości od miejsca akwizycji sygnałów EEG, mają duży wpływ na SNR. Wpływ EOG oraz EMG można zminimalizować poprzez uniknięcie nadmiernego mrugania, ruchu oczu oraz napinania mięśni.

Typowymi technikami usunięcia artefaktów z sygnału EEG są[43]:

Progowanie — jeżeli jakakolwiek charakterystyka sygnału EOG lub EMG przekracza zdefiniowany próg (ang. threshold), próbki sygnałów EEG w tej epoce zostają uznane za skażone i są odrzucane. Ten sposób może być zastosowany również dla akwizycji wyłącznie sygnałów EEG, jednak to podejście wymaga wstępnej kalibracji z użytkownikiem. Wadą tego rozwiązania jest utrata informacji zawartych w odrzuconych próbkach.

Filtracja — wycięcie z pobranego sygnału składowych o określonym paśmie częstotliwości przy użyciu filtra pasmowo–zaporowego. W celu przeprowadzenia filtracji należy przekształcić sygnał do dziedziny częstotliwości (na przykład przy użyciu FFT), wyciąć składowe o niepożądanej częstotliwości, a następnie przekształcić sygnał z powrotem do dziedziny czasu. Usunąć w ten sposób można między innymi zakłócenia sieci energetycznej⁶ oraz artefakty EOG (około 1÷4 Hz). Filtrację należy stosować, tylko jeżeli podlegające jej składowe mają inną częstotliwość niż sygnały, które chcemy uzyskać.

Regresja liniowa — przy założeniu, iż szum sygnału EEG jest addytywny można sformułować zależność w postaci[43]:

$$EEG_i(t) = EEG_i^{true}(t) + K \times EOG(t)$$

gdzie $EEG_i^{true}(t)$ jest czystym sygnałem EEG pozyskanym z elektrody i w czasie t , $EOG(t)$ jest sygnałem EOG w czasie t , a K stałą, która może być estymowana. Posiadając estymację stałej K , na podstawie prostego przekształcenia można uzyskać estymację czystego sygnału EEG w postaci:

$$EEG_i^{true}(t) = EEG_i(t) - K \times EOG(t)$$

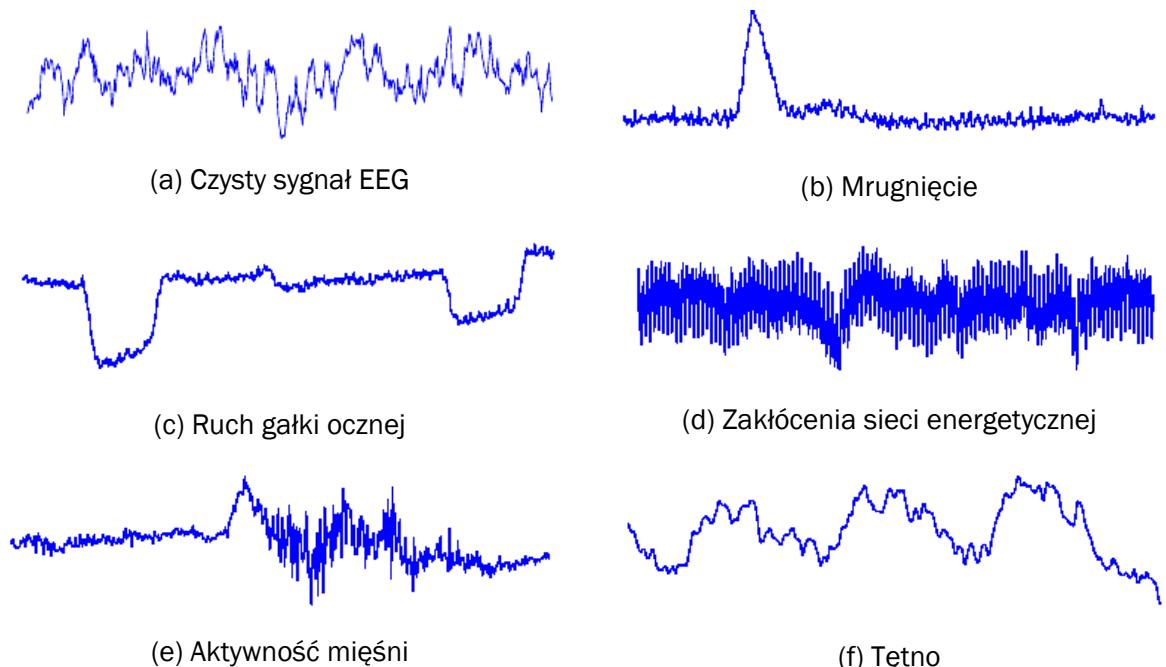
Ta metoda jest bardziej skomplikowana do usunięcia artefaktów EMG, ponieważ pochodzą one z wielu źródeł (wielu grup mięśni) i wymagają opracowania bardziej skomplikowanego modelu.

Analiza składowych głównych — inaczej PCA (ang. Principal Component Analysis); polega na redukcji współczynników potrzebnych do opisania dużej liczby skorelowanych

⁶W zależności od kraju zakłócenia te mogą występować w innym paśmie częstotliwości. W Europie jest to 50 Hz, ale na przykład w większości państw Ameryki Północnej częstotliwość sieci wynosi 60 Hz.

ze sobą zmiennych, przy jednoczesnym zachowaniu jak największej liczby składowych znajdujących się w sygnale właściwym. Umożliwia zmniejszenie ilości informacji zawartych w sygnale poprzez eliminację pewnych składowych zawierających artefakty[42]. PCA pozwala na usunięcie szumów związanych z EOG[43].

Analiza składowych niezależnych – inaczej ICA (ang. Independent Component Analysis); pozwala na estymację nieznanych sygnałów źródłowych oraz ekstrakcję zakłóceń w celu ich późniejszej eliminacji[42]. ICA stosuje się w celu eliminacji zakłóceń EOG oraz EMG[43].



Rysunek 1.4. Rodzaje artefaktów występujących w sygnałach EEG

Źródło: [10]

1.3.2. Ekstrakcja cech

Celem ekstrakcji cech (ang. feature extraction) jest przekształcenie surowych danych EEG do postaci nadającej się do wykorzystania w procesie klasyfikacji sygnałów[45].

Cecha jest właściwością opisującą sygnał EEG[7]. Cechą podstawową sygnału jest jego bezpośredni pomiar[47], na przykład różnica potencjałów pomiędzy dwoma elektrodami w chwili t . Podstawowe cechy są zazwyczaj przedstawiane w postaci cech złożonych, które stanowią ich liniowe oraz nieliniowe kombinacje, stosunki lub miary statystyczne. W celu jak najdokładniejszej detekcji intencji użytkownika wiele cech jest pozyskiwanych jednocześnie; są one zazwyczaj grupowane w tak zwane wektory cech[7].

Przykładem wykorzystania ekstrakcji cech może być rozpoznanie wyobrażenia ruchu ręką – cechą używaną do detekcji jest moc pasma μ ($8 \div 12$ Hz) oraz β ($16 \div 24$ Hz)[7].

W interfejsach mózg–komputer najczęściej wykorzystywane są cechy opisujące sygnał[6]:

Przestrzennie – służą do przybliżonego wyznaczania źródeł sygnału[6].

Spektralnie – opisują moc sygnału w zależności od częstotliwości[7].

Czasowo – opisują zmianę sygnału w czasie.

Innymi cechami wykorzystywanymi w BCI są reprezentacje czasowo-częstotliwościowe sygnałów, transformacja Hilberta oraz parametry Hjortha[45].

Problem ekstrakcji cech został poruszony szerzej w literaturze [6, 7, 43, 45, 47].

1.3.3. Klasyfikacja sygnałów

Klasyfikatory służą do rozpoznawania wzorców w wektorach cech sygnałów EEG. Ich zadaniem jest przekształcenie aktywności mózgu w sygnały użyteczne dla komputera.

Wśród klasyfikatorów można wyróżnić między innymi:

Klasyfikator liniowy – algorytm dyskryminacyjny posługujący się funkcjami liniowymi w celu rozróżnienia poszczególnych klas[26]. Wśród tego rodzaju klasyfikatorów w BCI najczęściej wykorzystywane są LDA⁷ oraz SVM⁸[19].

LDA jest liniowym klasyfikatorem binarnym, który przy pomocy hiperpłaszczyzny rozdziela dane reprezentujące różne klasy[26]. Metoda jest stosunkowo prosta i posiada małą złożoność obliczeniową, przez co jest często stosowana w BCI. Jej wadą jest osiąganie słabych rezultatów klasyfikacji w przypadku złożonych, nieliniowych wektorów cech sygnałów EEG[19].

SVM, podobnie jak LDA, używa hiperpłaszczyzny w celu rozdzielenia poszczególnych klas. W przypadku SVM poszukiwana hiperpłaszczyzna powinna rozdzielać z maksymalnym marginesem dane należące do odrębnych klas. Metoda posiada dobre właściwości generalizacji oraz jest niewrażliwa na przetrenowanie[6].

Sieci neuronowe – wśród sieci neuronowych wykorzystywanych w BCI najczęściej zastosowanie znajduje MLP⁹[26].

MLP składa się z kilku warstw neuronów: warstwy wejściowej, warstw ukrytych oraz warstwy wyjściowej. Wielowarstwowy perceptron jest wrażliwy na przetrenowanie, w szczególności w przypadku zaszumionych danych, takich jak sygnały EEG[19].

Innymi rodzajami sieci neuronowych wykorzystywanymi w BCI są między innymi LVQ, Fuzzy ARTMAP, RBF oraz BLRNN, ALN oraz PeGNC[26].

Naiwny klasyfikator bayesowski – jest klasyfikatorem probabilistycznym opartym na założeniu niezależności cech. Z tego powodu jest również zwany modelem cech niezależnych (ang. independent feature model). Rozpatrując klasyfikację jako zadanie przyporządkowania klasy do konkretnego wejścia na podstawie wektorów

⁷LDA (ang. linear discriminant analysis) – liniowa analiza dyskryminacyjna

⁸SVM (ang. support vector machine) – maszyna wektorów nośnych

⁹MLP (ang. multilayer perceptron) – wielowarstwowy perceptron

cech F_1, F_2, \dots, F_n , decyzję otrzymujemy poprzez wybranie klasy z największym prawdopodobieństwem:

$$P(C = i | F_1, \dots, F_n)$$

Na drodze przekształceń, korzystając z twierdzenia Bayesa, otrzymujemy prawdopodobieństwo w postaci:

$$P(C = i | F_1, \dots, F_n) = P(C = i)P(F_1 | C = i)P(F_2 | C = i) \dots P(F_n | C = i)$$

Mając równanie w tej postaci, wynik klasyfikacji otrzymujemy poprzez obliczenie prawdopodobieństwa dla każdej z klas, a następnie wybranie tej o największym prawdopodobieństwie[43].

Algorytm najbliższego sąsiada – klasa wyjściowa jest przydzielana na podstawie najbliższego sąsiada, który jest wyłaniany na przykład przy pomocy odległości euklidesowej między wektorami, danej wzorem[43]:

$$d_{x,y} = \sqrt{\sum_{n=1}^M (x_n - y_n)^2}$$

gdzie $d_{x,y}$ jest odlegością między wektorami x oraz y .

Klasyfikacja algorytmem najbliższego sąsiada NN (ang. nearest neighbor) jest podatna na szum[43]. Z tego powodu często jest zastępowana bardziej odporną odmianą w postaci algorytmu k najbliższych sąsiadów k-NN (ang. k nearest neighbors), w którym klasa jest przyporządkowywana na podstawie klasyfikacji k najbliższych sąsiadów.

W celu poprawy klasyfikacji można zastosować połączenie kilku różnych algorytmów. Ostateczne przyporządkowanie do konkretnej klasy następuje wtedy na drodze wzmacniania, głosowania lub nakładania.

Wzmacnianie (ang. boosting) wykorzystuje klasyfikatory połączone w kaskadę. Każdy klasyfikator stara się wyeliminować błąd wprowadzony przez poprzednie. Ten sposób łączenia pozwala na stworzenie wydajnego klasyfikatora z połączenia kilku słabych. Charakteryzuje się odpornością na przetrenowanie[19].

Przy głosowaniu (ang. voting) kilka klasyfikatorów samodzielnie dokonuje przydzielania danych wejściowych do odpowiedniej klasy. Klasa wynikowa zostaje wyłoniona na drodze głosowania, to jest zostaje nią klasa, która została wyłoniona najczęściej razy podczas samodzielnego klasyfikacji.

Nakładanie (ang. stacking) wykorzystuje dwa poziomy klasyfikatorów. Pierwszy, tak zwany poziom 0, klasyfikuje dane wejściowe do odpowiednich klas. Wyjścia klasyfikatorów poziomu 0 są połączone z wejściami klasyfikatora poziomu wyższego, zwanego poziomem 1, który podejmuje ostateczną decyzję dotyczącą przynależności do danej klasy[26].

Połączone klasyfikatory uzyskują lepsze rezultaty. Ich połączenie obniża wariancję oraz błąd klasyfikacji[26].

1.4. Przegląd potencjalnych zastosowań

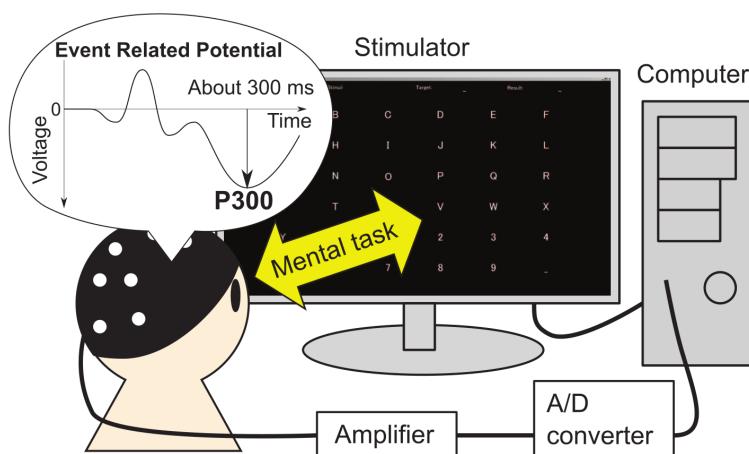
1.4.1. Interfejs komunikacyjny

Najprostsze interfejsy komunikacyjne można zrealizować dając użytkownikowi do wyboru dwie opcje: *tak* lub *nie*. Podejście dwuwartościowe pozwala na stosowanie różnorodnych technik akwizycji wyboru, między innymi poprzez analizę mrugnięć, ruchu gałek ocznych, czy sygnałów pochodzących z BCI. Przy tak skonstruowanym interfejsie osoba z niego korzystająca jest w stanie odpowiadać na pytania rozmówcy.

Taki sposób komunikacji może być zmodyfikowany w celu umożliwienia osobie użytkującej interfejs nadawania toku rozmowy. Dzięki zastosowaniu tablicy ze znakami, jej rozmówca może przemieszczać po kolej swój palec po literach alfabetu i notować te, dla których osoba korzystająca z interfejsu zakomunikowała odpowiedź *tak*. Wadą takiego rozwiązania jest fakt, iż rozmówca musi asystować osobie niepełnosprawnej, co może wprowadzać uczestników rozmowy w zakłopotanie. Taki interfejs charakteryzuje się małą stopą błędu, jednak komunikacja przy jego użyciu jest długotrwała i wynosi około jedno słowo na minutę[19].

Innym podejściem jest stworzenie systemu opartego o wirtualny kurSOR, który pozwoliłby użytkownikowi na samodzielnie wybieranie liter lub całych wyrazów spośród dostępnych opcji. Taki system może zawierać elementy autokorekty, aby zminimalizować występujące błędy.

W literaturze można również spotkać się z systemami badającymi potencjały wywołane. Taką metodą jest *P300*. W takim interfejsie użytkownik skupia swoją uwagę na literze, którą chce wybrać. Litery są samoczynnie podświetlane w losowej kolejności. 300 milisekund po podświetleniu litery, na której użytkownik systemu jest aktualnie skupiony, można zaobserwować zmianę amplitudy rejestrowanego sygnału EEG[43]. Przykładową realizację interfejsu opartego o analizę potencjału *P300* pokazano na rysunku 1.5.



Rysunek 1.5. Struktura interfejsu opartego o potencjał P300

Źródło: [34]

1.4.2. Sterowanie wózkiem inwalidzkim

Osoby sparaliżowane niekiedy są w stanie sterować wózkiem inwalidzkim, używając do tego celu wydmuchiwanego powietrza, mowy lub, w przypadku częściowego paraliżu, sprawnych części ciała. Integracja z interfejsami mózg–komputer stwarza nowe możliwości dla osób, które z powodu poważniejszych schorzeń nie są w stanie skorzystać z wyżej wymienionych metod sterowania.

Kontrola wózka inwalidzkiego może odbywać się przy wykorzystaniu sterowania nisko- lub wysokopoziomowego.

Sterowanie niskopoziomowe można zrealizować przez translację sygnałów odebranych z urządzenia rejestrującego aktywność mózgu na komendy opisujące ruch wózka (*ruch do przodu, zawróć, przyspiesz*), z zastrzeżeniem, że użytkownik wydaje je w sposób bezpośredni. Ten rodzaj sterowania wymaga zamontowania czujników na wózku, które uniemożliwią wykonanie niedozwolonych manewrów, na przykład uderzenia w inną osobę lub przedmiot. Do zalet rozwiązania można zaliczyć wysoki stopień kontroli osoby użytkującej wózek nad sposobem przemieszczania oraz stosunkowo małą ilość wymaganych komend mentalnych do podstawowego sterowania. Do wad należy konieczność wydawania poleceń ruchu w sposób ciągły, co może prowadzić do znużenia użytkownika, a w konsekwencji samoczynnego *rozstrajania się* układu sterowania.

Sterowanie wysokopoziomowe polega na wydawaniu poleceń dotyczących celu ruchu (*kuchnia, łazienka*). Podejście to wiąże się z koniecznością stosowania wózków o wysokim stopniu autonomiczności. Zaletą tego rozwiązania jest odciążenie użytkownika od konieczności utrzymywania ciągłego skupienia na kierunku oraz prędkości ruchu, wyeliminowanie wpływu zakłóceń odbieranych w trakcie przemieszczania się oraz, po zapewnieniu skutecznych algorytmów i odpowiedniej ilości czujników, bezpieczniejsze poruszanie się w środowisku. Do wad zaliczyć należy większą ilość komend, które należy zdefiniować (co najmniej po jednej dla każdego pomieszczenia), mniejszą precyzję ruchu, spowodowaną odgórnym określeniem miejsca w pomieszczeniu, do którego użytkownik chce się przemieścić oraz konieczność zdefiniowania i zmapowania każdego środowiska, w którym będzie poruszał się wózek.

Mimo obiecujących wstępnych rezultatów, wykorzystanie interfejsów mózg–komputer do zadania sterowania wózkami inwalidzkimi jest trudne do zrealizowania z powodu braku niezawodnych, przenośnych i łatwych w użyciu urządzeń rejestrujących. Inną przeszkodą jest brak wózków o wystarczającym stopniu autonomiczności, które byłyby zdalne do pracy w codziennym środowisku[43].

1.4.3. Rehabilitacja

Można wyróżnić trzy główne sposoby wsparcia rehabilitacji medycznej przez interfejsy mózg–komputer[9]:

mózg–akcja – polega na nauczeniu pacjenta przy pomocy BCI wydawania odpowiednich poleceń, wymaganych do usprawnienia motoryki kończyn,

mózg–kończyna – polega na wykorzystaniu BCI do kontroli urządzenia wspierającego

poruszanie się, a w konsekwencji odbudowania połączeń potrzebnych do poruszania się bez niego,

mózg–mózg – na podstawie informacji odebranych z systemu BCI następuje stymulacja mózgu w celu poprawy jego aktywności, aż do osiągnięcia zadowalających wyników.

Należy nadmienić, iż te sposoby nie są wzajemnie wykluczające – ich połączenie pozwala na zwiększenie znaczenia BCI w tej dziedzinie nauki.

Interfejsy mózg–komputer, poprzez stopniową integrację z neurorehabilitacją, mogą pomóc między innymi osobom dotkniętym udarem mózgu, który często powoduje długotrwałą niepełnosprawność ruchową oraz zaburzenia funkcji poznawczych. Wiele badań wykazuje, iż technika nieinwazyjnej stymulacji mózgu jest skuteczna, nawet w przypadku przewlekłego uszkodzenia mózgu[9]. Duża ilość osób rokrocznie dotykanych udarem stanowi badania w tym zakresie niezwykle istotnymi dla społeczeństwa.

Stosowanie BCI do wspomagania leczenia funkcji poznawczych wymaga skrupulatnej identyfikacji sygnałów mózgowych, które są możliwe do uzyskania. Może to być trudne, ponieważ nie wszystkie stany mózgu są tak dobrze scharakteryzowane, jak te związane z funkcjami motorycznymi[29].

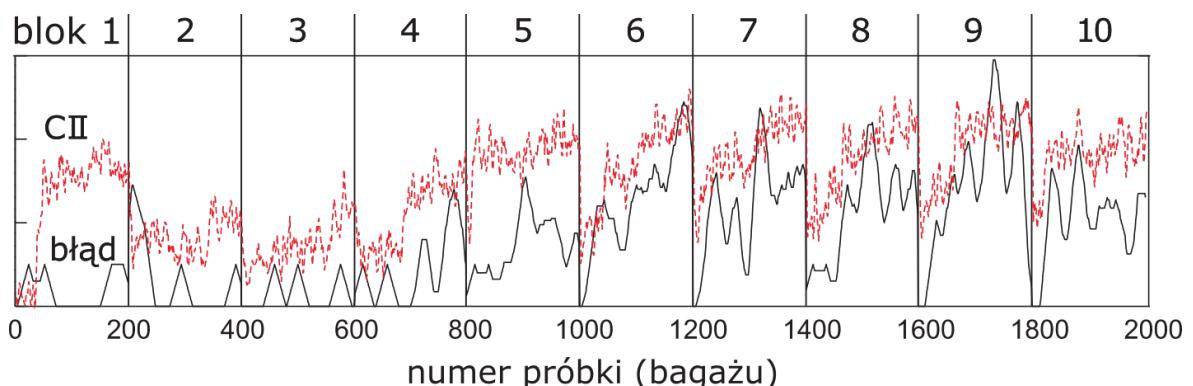
1.4.4. Nadzór skupienia

Wykorzystanie interfejsów mózg–komputer do nadzorowania skupienia użytkownika jest szczególnie istotne w asystowaniu pracowników wykonujących monotonne prace, takie jak prowadzenie samochodu czy monitorowanie systemu zabezpieczeń. Popełnienie błędu w przypadku takich profesji powoduje nie tylko ryzyko dla samego pracownika, ale również dla innych osób znajdujących się w jego otoczeniu. Wiele wypadków jest spowodowanych zmęczeniem, nieuwagą lub nawet zaśnięciem podczas wykonywania pracy. Choć znużenie lub senność może być wykryta przez analizowanie obszaru okolic oczu, taka detekcja może mieć miejsce za późno, aby było możliwe zapobiegnięcie wypadkowi. Integracja BCI z urządzeniami do nadzoru niesie możliwość wykrywania takich sytuacji, zanim doprowadzą do katastrofalnych w skutkach wydarzeń.

W związku z postępującą automatyzacją pojazdów, kierowca jest odciążany od wykonywania żmudnych zadań, takich jak utrzymywanie stałej prędkości czy przełączanie między światłami mijania oraz drogowymi. Wraz z dalszym progresem coraz więcej czynności wykonywanych jest przez sam samochód, podczas gdy rola osoby znajdującej się w fotelu kierowcy sprowadza się do nadzoru i reagowania w niebezpiecznych sytuacjach. Może to prowadzić, w szczególności na trasach o znacznej długości, do sytuacji nadmiernego zaufania do systemu sterowania, w której to kierowca przestanie zwracać uwagę na działania pojazdu. Interfejs mózg–komputer mógłby w tym momencie sygnalizować spadek skupienia kierowcy lub wymuszać bezpieczny postój pojazdu do momentu, w którym kierujący pojazdem będzie w stanie kontynuować podróż.

Badania przeprowadzone przez naukowców z *Berlin BCI* wykazały, iż istnieje za-

leżność pomiędzy spadkiem koncentracji, a wzrostem mocy w paśmie alpha¹⁰[4]. Badanie polegało na sklasyfikowaniu 2000 bagażów jako bezpiecznych lub niebezpiecznych na podstawie ich prześwietleń. Wykonano je w 10 turach po 200 bagażów. Zarejestrowaną zależność pomiędzy parametrem CII (ang. concentration insufficiency index), a stopą błędu przedstawiiono na rysunku 1.6. Na podstawie badania można wywnioskować, iż spadek koncentracji (wzrost parametru CII) prowadził do wzmożenia ilości popełnianych błędów. Uczestnicy rzeczonego badania na okres następujący bezpośrednio po przerwie wykazywali znacznie niższy stopień błędu. Tę zależność można wykorzystać do określenia momentów, w których pracownik powinien udać się na przerwę lub, w przypadku dłucho-trwałej nikłej koncentracji, zakończyć swoją zmianę.



Rysunek 1.6. Zależność pomiędzy stopniem skupienia CII, a stopą błędu. Pionowe linie po za-kończeniu dwustuprobkowych bloków oznaczają moment przerwy.

Źródło: [4]

1.4.5. Gry komputerowe

Wprowadzenie dedykowanych rozwiązań dla przemysłu gier komputerowych wydaje się być kolejnym krokiem po rozwoju aplikacji korzystających z technologii VR¹¹ oraz AR¹². To, co sprawia, że gracze są odpowiednim odbiorcą wczesnych systemów BCI jest fakt, iż często są oni zainteresowani nowymi technologiami, są skłonni do jej wdrażania w celu uzyskania przewagi nad przeciwnikami oraz przyzwyczajeni do konieczności treningu, który pozwala na progres w grach[33]. W związku z dynamicznym rozwojem tej branży, opracowanie rozwiązań wykorzystujących BCI może być bardzo opłacalne w przyszłości.

Wykorzystanie BCI w grach komputerowych pozwala na integrację gry z wrażeniami użytkownika. Dostarczenie informacji na temat skupienia, zainteresowania, frustracji czy znudzenia umożliwia grze dostosowanie się do potrzeb gracza. W przypadku narastania frustracji gra może samoczynnie obniżyć poziom trudności, a w przypadku znudzenia – podwyższyć. Wykorzystując inne odczucia gra może również uprościć interfejs użytkowni-

¹⁰Pasmo alpha - pasmo fal elektromagnetycznych o częstotliwości 8÷12 Hz i amplitudzie w zakresie 20÷80 µV[29, str. 17].

¹¹VR (ang. virtual reality) – rzeczywistość wirtualna

¹²AR (ang. augmented reality) – rzeczywistość rozszerzona

ka, czy też wyświetlić lub ukryć podpowiedzi dotyczące aktualnie wykonywanego zadania (ang. quest). Dynamiczne dostosowywanie gry do aktualnego stanu gracza pozwala jej na zapewnienie użytkownikowi zwiększonego komfortu podczas rozgrywki.

Innym zastosowaniem interfejsów mózg–komputer jest wydawanie poleceń za pomocą komend mentalnych. Polecienniem może być na przykład wyobrażenie sobie ruchu postaci, co prowadziłoby do faktycznego przemieszczania się kontrolowanego bohatera, czy wybieranie odpowiedzi w dialogach występujących w grze. Wiąże się to z całkowitą zależnością gry od sygnałów otrzymywanych z urządzenia rejestrującego i wnosi konieczność znacznej modyfikacji istniejących silników gier.

Zintegrowanie BCI z grami komputerowymi wiąże się nie tylko ze znacznymi inwestycjami ze strony producentów gier, ale również samych graczy, którzy będą musieli zakupić urządzenie rejestrujące aktywność mózgu. Należy zwrócić uwagę na fakt, że rozgrywki często prowadzone są przez długi okres, a więc wymogiem stawianym przed systemami rejestrującymi jest ich wygoda. Nie mogą one ograniczać ruchów użytkownika ani jego pola widzenia. Wadą rozwiązania jest fakt, iż gracze często generują napięcia mięśniowe, co będzie prowadziło do powstawania artefaktów w przypadku urządzeń rejestrujących sygnały EEG. Rozwiązaniem tego problemu może być ulepszenie algorytmów filtracji sygnałów lub stosowanie systemów hybrydowych EEG/EMG, a więc rejestrujących oraz wykorzystujących aktywność zarówno mózgu, jak i mięśni[43].

ROZDZIAŁ 2

Charakterystyka wybranych urządzeń komercyjnych

2.1. Emotiv Insight

Insight (patrz rysunek 2.1) jest produktem wprowadzonym na rynek w roku 2015 przez firmę Emotiv przy wsparciu crowdfundingu na portalu kickstarter. Jest produktem do użytku codziennego, głównie za sprawą minimalistycznego designu oraz braku konieczności stosowania żelów przewodzących, przeznaczonym do mniej precyzyjnych zastosowań.

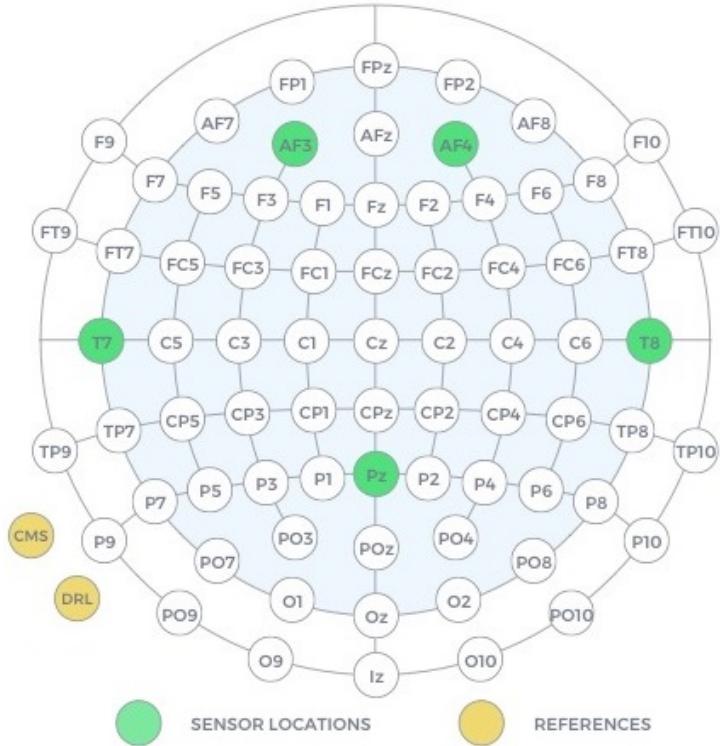
Jest wyposażony w pięć czujników właściwych oraz dwa referencyjne. Lokalizacja czujników została przedstawiona na rysunku 2.2 na następnej stronie. Czas ubrania oraz ustawienia urządzenia oscyluje w granicach 1–2 minut. Parametry urządzenia zostały zestawione w tabeli 2.1 na następnej stronie.

Koszt produktu na dzień 21 kwietnia 2019 roku wynosi 299\$.



Rysunek 2.1. Hełm Emotiv Insight

Źródło: [13]



Rysunek 2.2. Rozmieszczenie sensorów w hełmie Emotiv Insight

Źródło: [13]

Tabela 2.1. Parametry Emotiv Insight

Źródło: Opracowanie własne na podstawie [15]

Ilość kanałów	5 (+2 referencyjne)
Umiejscowienie elektrod	AF3, AF4, T7, T8, Pz
Czujniki referencyjne	DMS/DRL
Rodzaj czujników	Półsuchy polimer
Rozdzielcość	14 bit na kanał
Rozdzielcość LSB	0,51 µV @ 14 bit
Detekcja ruchu	9-osiowy czujnik (3x żyroskop, 3x akcelerometr, 3x magnetometr)
Łączność	Bezprzewodowa 2,4GHz/Bluetooth 4.0
Zasilanie	Li-Po 480 mAh, do 8 godzin pracy

Firma Emotiv dostarcza do swoich rozwiązań API¹ o nazwie Cortex. Stanowi on podstawę do budowania aplikacji wykorzystujących pobrane z hełmów strumienie danych dzięki wykorzystaniu JSON oraz WebSocket[11]. Cortex ułatwia tworzenie gier, aplikacji oraz rejestrowania danych do późniejszego ich wykorzystania do badań.

Cortex jest wrapperem SDK² firmy EMOTIV. Zapewnia on, w zależności od rodzaju

¹API (ang. application programming interface) – Interfejs programistyczny aplikacji. Zawiera zestaw reguł i ich opisów, które definiują sposób komunikacji między programami komputerowymi.

²SDK (ang. software development kit) – Zestaw narzędzi dla programistów niezbędny w tworzeniu aplikacji korzystających z danej biblioteki.

zakupionej licencji, dostęp do różnych strumieni danych z hełmów. Jest kompatybilny z systemami Mac OS oraz Windows. Umożliwia programowanie w językach Java, C#, C++, Python, Ruby, JavaScript (Node.js) oraz PHP.

Licencja Cortex jest dostępna w trzech planach:

Darmowa

- Mental Commands API,
- Performance Metrics API (do 0,1 Hz),
- Frequency Bands API,
- Facial Expressions API,
- Motion data API,
- nielimitowana ilość sesji na 3 urządzeniach.

Niekomercyjna pro – \$55-99/miesiąc

- Wszystkie API z licencji darmowej,
- Raw EEG API,
- oprogramowanie EmotivPRO,
- nielimitowana ilość sesji na 3 urządzeniach.

Komercyjna

- Performance Metrics API o wysokiej rozdzielczości,
- konfigurowanie API pod swoje potrzeby,
- tworzenie komercyjnych rozwiązań.

Oprogramowanie EmotivPRO[14], dostępne w licencjach niekomercyjnej pro oraz komercyjnej, stanowi wsparcie dla badań wykorzystujących EEG. Pozwala ono na akwizycję oraz prezentację strumieni danych w czasie zbliżonym do rzeczywistego, zapisywanie sesji w chmurze oraz szybką analizę wbudowanym algorytmem FFT³, bez konieczności eksportu danych.

2.2. Emotiv EPOC+

EPOC+, pokazany na rysunku 2.3 na następnej stronie, został wprowadzony na rynek w 2013 roku przez firmę Emotiv. Został zaprojektowany do badań wykorzystujących EEG oraz zaawansowanych zastosowań BCI[12].

Jest wyposażony w 14 kanałów właściwych oraz 2 referencyjne (dokładna lokalizacja sensorów została przedstawiona na rysunku 2.4 na następnej stronie). W odróżnieniu od Emotiv Insight, omówionego w rozdziale 2.1 na stronie 25, wymaga stosowania

³FFT (ang. Fast Fourier Transform) – Szybka transformacja Fouriera.

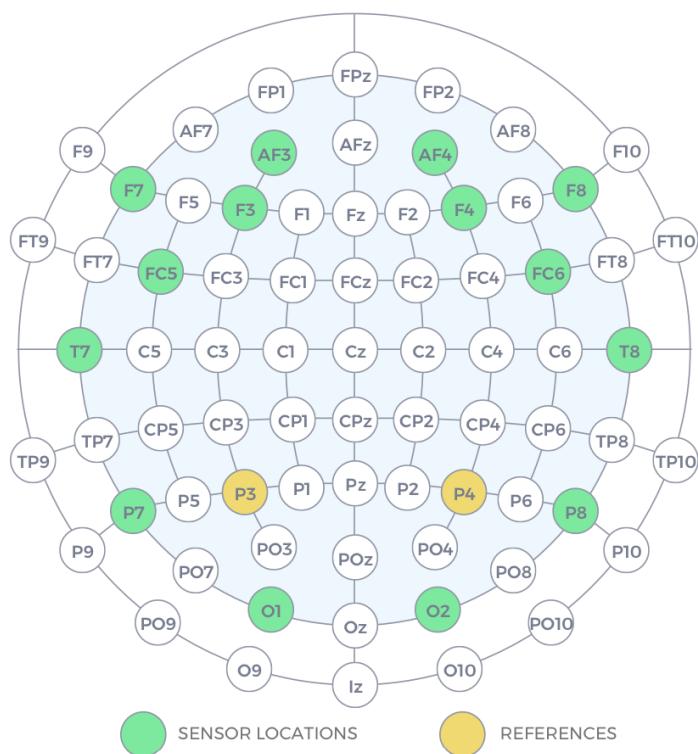
mokrych elektrod, pokrytych nasączonym solą fizjologiczną filcem. Ze względu na większą ilość czujników niż w Emotiv Insight, czas ubrania oraz przygotowania urządzenia do pracy wynosi około 3–5 minut. Parametry hełmu zostały przedstawione w tabeli 2.2 na sąsiedniej stronie.

Koszt produktu na dzień 21 kwietnia 2019 roku wynosi 799\$.



Rysunek 2.3. Hełm Emotiv EPOC+

Źródło: [12]



Rysunek 2.4. Rozmieszczenie sensorów w hełmie Emotiv EPOC+

Źródło: [12]

Tabela 2.2. Parametry Emotiv EPOC+

Źródło: Opracowanie własne na podstawie [15]

Ilość kanałów	14 (+2 referencyjne)
Umiejscowienie elektrod	AF3, AF4, F3, F4, FC5, FC6, F7, F8, T7, T8, P7, P8, O1, O2
Czujniki referencyjne	DMS/DRL
Rodzaj czujników	Nasączane solą fizjologiczną
Rozdzielcość	14/16 bit na kanał
Rozdzielcość LSB	0,51 µV @ 14 bit/0,13 µV @ 16 bit
Detekcja ruchu	9-osiowy czujnik (3x żyroskop, 3x akcelerometr, 3x magnetometr)
Łączność	Bezprzewodowa 2,4GHz/Bluetooth 4.0
Zasilanie	Li-Po 680 mAh, do 12 godzin pracy

Od strony programistycznej urządzenie wykorzystuje to samo API oraz SDK co Emotiv Insight; zostały one omówione w rozdziale 2.1 na stronie 25.

2.3. Muse/Muse 2

Muse/Muse 2 są urządzeniami wspomagającymi medytację, które pozwalają na rejestrację w czasie rzeczywistym aktywności mózgu, tętna, oddechu oraz ruchu ciała⁴[21]. Przekształcają one zmierzoną aktywność mózgu w predefiniowane dźwięki, takie jak szum wody czy deszczu; w zależności od poziomu skupienia dźwięk będzie spokojny lub gwałtowny, co pozwala osobom uczącym się medytować na efektywniejszą naukę wyciszenia umysłu.

Oba urządzenia są z wyglądu bardzo do siebie podobne. Nowsze, Muse 2 (pokazane na rysunku 2.5 na następnej stronie), w odniesieniu do poprzedniej wersji, zostało *odchudzone*, przez co nabralo bardziej eleganckiego wyglądu oraz zyskało niższy profil z dodatkowymi czujnikami[24]. Dodano również miękkie w dotyku wykończenie.

Obie opaski są wyposażone w 7 czujników, w tym 3 referencyjne (patrz rysunek 2.6 na następnej stronie). Zestawienie parametrów oferowanych przez obie opaski znajduje się w tabeli 2.3 na stronie 31.

Koszt Muse wynosi 219€; Muse 2 – 269€.

Muse posiada oferty skierowane do następujących grup:

Deweloperów – na dzień 23 kwietnia 2019 roku Muse nie wspiera aktywnie swojego SDK⁵. Ostatnią dostępną wersją jest v6.0.3, wydana w marcu 2018 roku. Opaska Muse 2, z racji późniejszej daty premiery, **nie jest wspierana przez SDK**. Na stronie dla deweloperów[22] znajduje się odnośnik do innych narzędzi, takich jak Muse Direct czy projektów open source, np. MuseLSL, EEG Notebooks.

Profesjonalistów – w ramach subskrypcji Muse Connect profesjonalisci otrzymują program wspomagający rozwój ich biznesu poprzez uczenie ich klientów technik me-

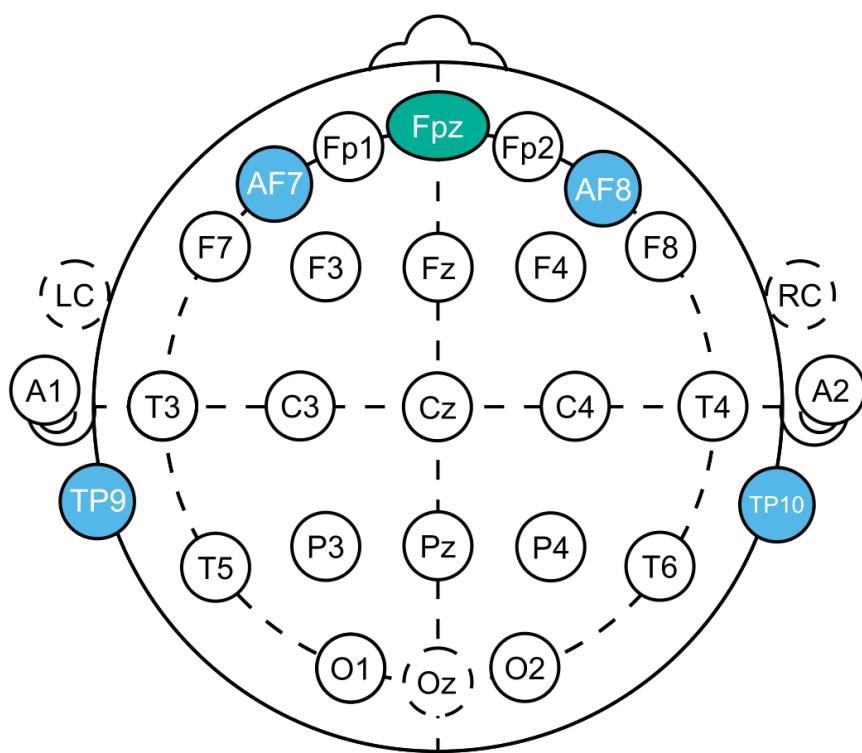
⁴Rejestracja poszczególnych parametrów w zależności od wersji opaski.

⁵SDK – Patrz przyp. 2 na stronie 26.



Rysunek 2.5. Opaska Muse 2

Źródło: [21]



Rysunek 2.6. Rozmieszczenie sensorów w opasce Muse

Źródło: [44]

dytacji[23]. W ten sposób otrzymują dostęp do różnych wskazówek m.in. webinariów⁶, studiów przypadków oraz informacji, które pomogą wprowadzić Muse do ich biznesu. Muse Connect wspomaga prowadzenie podopiecznych: ustalanie dla nich celów do realizacji oraz śledzenie ich progresu (również w czasie rzeczywistym).

Aplikacja oferuje dwa rodzaje subskrypcji:

⁶Webinarium – Internetowe seminarium realizowane przy wykorzystaniu streamingu wideo.

Tabela 2.3. Parametry Muse oraz Muse 2

Źródło: Opracowanie własne na podstawie [20] oraz [44]

Parametr	Muse	Muse 2
Ilość kanałów	4 (+ 3 referencyjne)	4 (+3 referencyjne)
Umiejscowienie elektrod	TP9, AF7, AF8, TP10 ^a	TP9, AF7, AF8, TP10 ^a
Czujniki referencyjne	CMS/DRL	CMS/DRL
Rodzaj czujników	Suche srebrne/silikonowe	Suche srebrne/silikonowe
Rozdzielcość	12 bit na próbkę	12 bit na próbkę
Rejestrowane parametry	EEG	EEG, tętno, ruch ciała, oddech
Kompatybilność	iOS, Android	iOS, Android
Łączność	Bezprzewodowa Bluetooth 4.0	Bezprzewodowa Bluetooth 5.0
Zasilanie	Li-Ion, do 5 godzin pracy	Li-Ion, do 5 godzin pracy

^a Dokładna lokalizacja zależy od wielkości głowy użytkownika; zamieszczono lokalizację zgodną z [44]. W literaturze można spotkać również T9, FP1, FP2, T10[2].

1. miesięczną w cenie 39\$/miesiąc,
2. roczną w cenie 33\$/miesiąc; w tej opcji dodatkowo otrzymujemy za darmo urządzenie Muse.

Naukowców – w ramach narzędzi dla naukowców Muse oferuje dostęp do MusePlayer oraz MuseLab. MusePlayer służy do rejestracji, ponownego odtwarzania, przekierowywania oraz przetwarzania danych z opasek. Umożliwia konwersję z natywnego typu danych (.muse) na inne (.txt, .mat, .csv). MuseLab wykorzystuje się do wizualizacji danych.

2.4. MindWave Mobile 2

MindWave Mobile 2 zbudowane jest z opaski na głowę, klipsu na ucho oraz ramienia z zamocowanym czujnikiem (patrz rysunek 2.7 na następnej stronie). Elektrody referencyjne oraz uziemiające znajdują się na klipsie na uchu, a elektroda EEG na ramieniu dotykającym czoła w pozycji FP1. Umożliwia pomiar sygnałów EEG, sygnałów NeuroSky eSense, na które składają się skupienie oraz medytacja, oraz mrugnięcie. Do zasilania wykorzystywana jest pojedyncza bateria AAA, która stara się na 8 godzin pracy[30].

Parametry urządzenia zostały zestawione w tabeli 2.4 na następnej stronie.

Koszt urządzenia na dzień 25 czerwca 2019 roku wynosi 100\$.

NeuroSky dostarcza swoje API dla systemów iOS, Android, macOS oraz Windows. Darmowe narzędzia dla deweloperów składają się z trzech osobnych API[31]:

ThinkGear Connector (TGC) – program działający w tle systemu operacyjnego; zarządza komunikacją z hełmem przy pomocy TCP/IP.

ThinkGear Communication Driver (TGCD) – biblioteka zawierająca funkcje pozwalające na połączenie oraz przetwarzanie danych z hełmu. Można ją wykorzystywać z językami C/C++, Java oraz C#.



Rysunek 2.7. Hełm MindWave Mobile 2

Źródło: [30]

Tabela 2.4. Parametry MindWave Mobile 2

Źródło: Opracowanie własne na podstawie [30]

Ilość kanałów	1
Umiejscowienie elektrod	FP1
Czujniki referencyjne	<i>brak danych</i>
Rodzaj czujników	<i>brak danych</i>
Rozdzielcość	12 bit
Częstotliwość próbkowania	512 Hz
Detekcja ruchu	Brak
Łączność	Bezprzewodowa Bluetooth (BT/BLE)
Zasilanie	1,5 V (1 bateria AAA), do 8 godzin pracy

Protokół komunikacji MindSet – zawiera specyfikacje protokołu komunikacyjnego; pozwala na integrację hełmu z dowolną platformą/językiem programowania.

Dodatkowo można wykupić narzędzia dla naukowców w cenie 500\$, na które składają się[32]:

NeuroView – aplikacja do wyświetlania oraz zapisywania danych EEG w czasie rzeczywistym. Pozwala na rejestrację czystego sygnału EEG, jego poszczególnych składowych oraz odczytów NeuroSky eSense dla skupienia oraz medytacji. Umożliwia eksport do plików CSV.

NeuroSkyLab – aplikacja zapewniająca integrację ze środowiskiem MATLAB.

2.5. OpenBCI Ultracortex Mark IV

Ultracortex, pokazany na rysunku 2.8 na następnej stronie, jest open source'owym hełmem zaprojektowanym do pracy ze wszystkimi układami OpenBCI[41]. Pozwala na rejestrację sygnałów EEG, EMG oraz ECG. Wspiera do 16 kanałów rozmieszczonych na 35 różnych lokalizacjach według systemu 10-20⁷.

W projekcie zastosowano *suche* sensory EEG. Ich rozmieszczenie pokazano na rysunku 2.9 na następnej stronie.

Czas założenia oraz uruchomienia hełmu wynosi poniżej 30 sekund.

Produkt można kupić w trzech wariantach:

1. Do samodzielnego druku – dostarczane są wszystkie części hełmu oprócz tych, które można wydrukować na drukarce 3D. Hełm należy zmontować samodzielnie na podstawie dokumentacji. Cena: 300–400\$.
2. Niezmontowany – dostarczane są wszystkie części hełmu, również z tymi, które można wydrukować na drukarce 3D. Hełm należy zmontować samodzielnie na podstawie dokumentacji. Cena: 500–600\$.
3. Zmontowany – dostarczany jest całkowicie zmontowany hełm. Cena: 700–850\$.

Dodatkowo należy zakupić wybraną płytę OpenBCI. Poniżej zamieszczono zwięzłe opisy dostępnych układów. Parametry hełmu *Mark IV* w połączeniu z kompatybilnymi płytami zamieszczono w tabeli 2.5 na stronie 36.

Ganglion Board – Ganglion (patrz rysunek 2.10 na stronie 35) posiada 4 kanały, które mogą być użyte do mierzenia sygnałów EMG, EKG lub EEG[38]. Częstotliwość próbkowania wynosi 200 Hz.

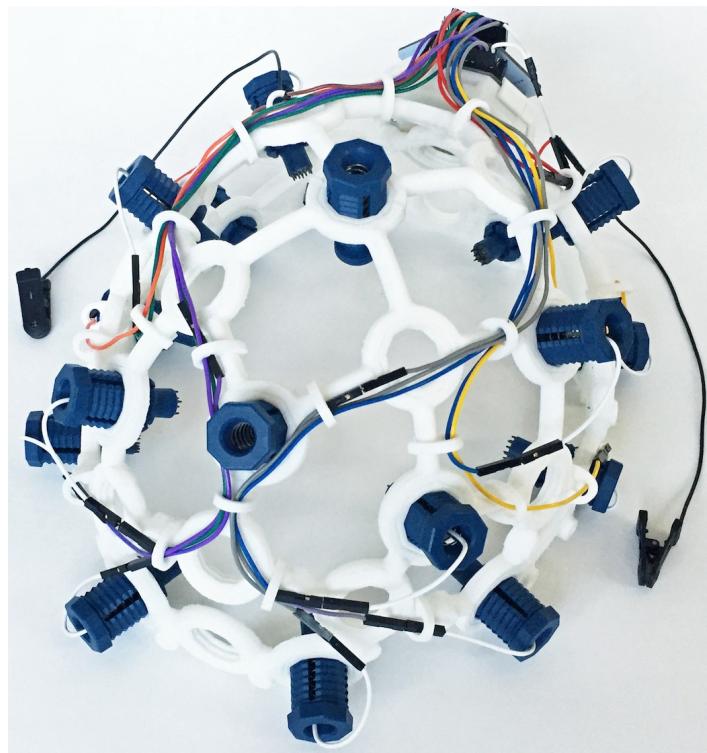
Komunikacja bezprzewodowa jest realizowana z wykorzystaniem Simblee BLE, modułu Bluetooth 4.0 kompatybilnego z Arduino, który pozwala na łatwą integrację z IoT⁸. Moduł umieszczony na płycie Ganglion jest zaprogramowany i gotowy do pracy, jednak część jego wyprowadzeń pozostaje dostępna dla użytkownika do celów własnych.

Koszt układu to 200\$.

Cyton Board – Cyton, pokazany na rysunku 2.11 na stronie 35, jest kompatybilny z Arduino, posiada 8 kanałów oraz 32-bitowy procesor[37]. Podobnie jak Ganglion,

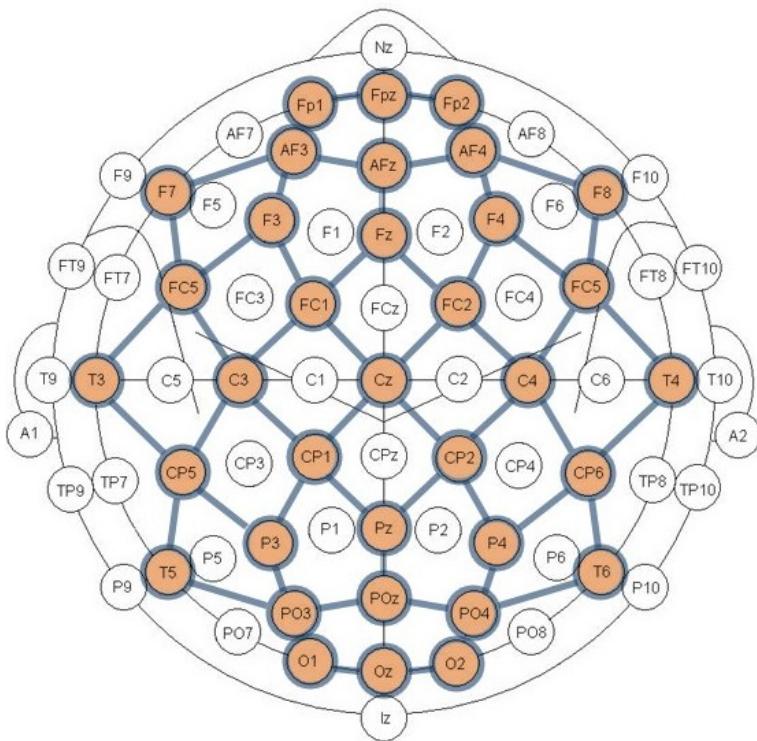
⁷System 10-20 – system opisu umiejscowienia elektrod; składa się z 21 elektrod. Podstawą tego standardu jest zdefiniowanie konturów między punktami orientacyjnymi czaszki (np. nasion, inion), a następnie podzielenie ich na proporcjonalne odległości 20% całkowitej długości. Istnieją również systemy pokrewne, np. 10-10 oraz 10-5, które używają odpowiednio 10% oraz 5% całkowitej długości[47, rozdz. 6].

⁸IoT (ang. Internet of Things) – Internet rzeczy. Koncepcja zgodnie z którą urządzenia mogą komunikować się ze sobą, wykorzystując do tego celu internet.



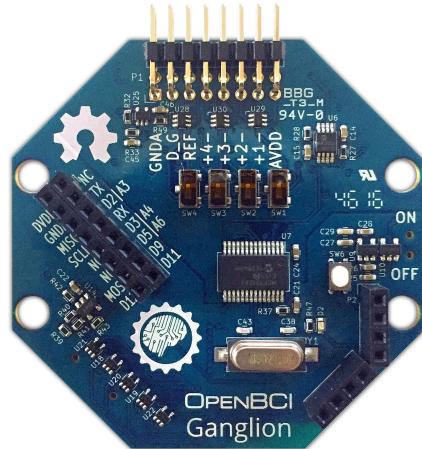
Rysunek 2.8. Hełm Ultracortex Mark IV

Źródło: [40]



Rysunek 2.9. Rozmieszczenie sensorów w hełmie Ultracortex Mark IV

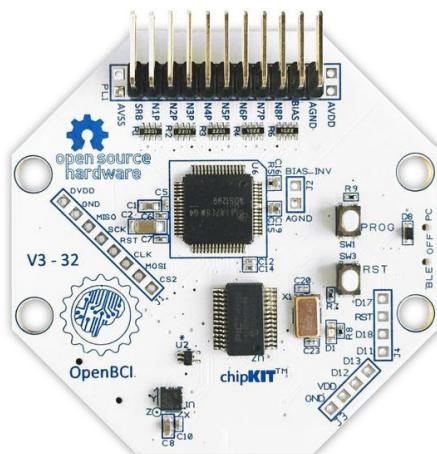
Źródło: [41]



Rysunek 2.10. OpenBCI Ganglion Board

Źródło: [38]

może być wykorzystany do mierzenia aktywności mięśni, serca lub mózgu. Dane próbkiowane są z częstotliwością 250 Hz.



Rysunek 2.11. OpenBCI Cyton Board

Źródło: [37]

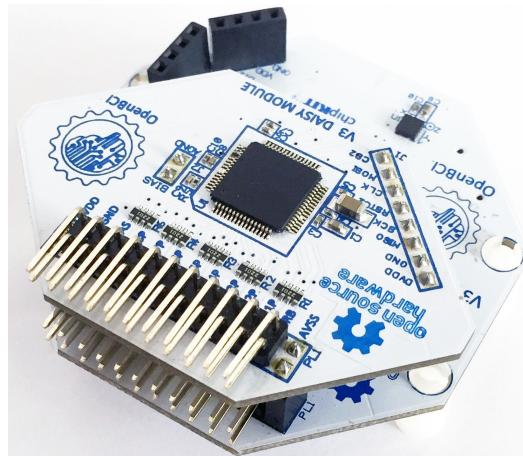
Do komunikacji bezprzewodowej wykorzystywany jest moduł RFduino. Komunikacja z komputerem może być realizowana przy pomocy adaptera OpenBCI USB lub, jeżeli komputer posiada tę opcję, wbudowanego modułu BLE⁹.

Koszt płytki to 500\$.

Cyton + Daisy Board – Ten układ zawiera opisaną wcześniej płytę Cyton oraz Daisy, która jest wpinana w płytę Cyton. Układ pokazano na rysunku 2.12 na następnej stronie.

⁹BLE (ang. Bluetooth Low Energy) – technologia sieci bezprzewodowej o poborze mocy niższym niż w konwencjonalnych modułach Bluetooth.

Daisy zapewnia dodatkowe 8 kanałów, które mogą być użyte do mierzenia EMG, EKG lub EEG[36]. Częstotliwość próbkowania wynosi 250 Hz.



Rysunek 2.12. OpenBCI Cyton + Daisy Board

Źródło: [36]

Koszt układu to 950 \$. Płytki Daisy nie może być zakupiona oddzielnie.

Tabela 2.5. Parametry Ultracortex Mark IV w połączeniu z kompatybilnymi układami

Źródło: Opracowanie własne na podstawie [41], [38],[37] oraz [36]

Parametr	Ganglion	Cyton	Cyton + Daisy
Ilość kanałów	4	8	16
Umiejscowienie elektrod	Konfigurowalne ^a	Konfigurowalne ^a	Konfigurowalne ^a
Rodzaj czujników	Suche	Suche	Suche
Rozdzielcość	24 bit	24 bit	24 bit
Częstotliwość próbkowania	200 Hz	250 Hz	250 Hz
Rejestrowane parametry	EMG, EKG, EEG ^b	EMG, EKG, EEG ^b	EMG, EKG, EEG ^b
Detekcja ruchu	3 osiowy akcelerometr	3 osiowy akcelerometr	3 osiowy akcelerometr
Kompatybilność	macOS, Windows, Linux	macOS, Windows, Linux	macOS, Windows, Linux
Łączność	BLE 4.0 przez adapter	BLE	BLE
Zasilanie	6V (4 baterie AA)	6V (4 baterie AA)	6V (4 baterie AA)

^a Mark IV wspiera 35 lokalizacji według standardu 10-20. Punkty w których można umieścić elektrody pokazano na rysunku 2.9 na stronie 34.

^b Sensory nie są dołączane do płyt i należy je zakupić oddzielnie.

Oprogramowanie OpenBCI jest open source'owe i jest dostępne na ich profilu na GitHubie.

Głównym narzędziem do wizualizacji, nagrywania oraz komunikacji z płytami jest OpenBCI GUI[39]. Narzędzie jest kompatybilne z systemami macOS, Windows oraz Linux. Pozwala na filtrowanie oraz przetwarzanie danych w czasie rzeczywistym. Dodatkowo pozwala na przekierowywanie danych wykorzystując protokoły UDP, OSC, LSL oraz port szeregowy.

Do komunikacji z płytami używane są OpenBCI Ganglion SDK oraz OpenBCI Cyton SDK. Wykorzystują one protokół oparty na znakach ASCII¹⁰.

OpenBCI dostarcza również bibliotekę Brainflow, która służy do analizy danych EMG, EKG oraz EEG[35]. Została ona napisana w języku C/C++, jednak zawiera nakładki na języki Python, Java, R, C++¹¹, Matlab oraz C#.

Platforma OpenBCI umożliwia również współpracę z innymi programami do analizy sygnałów, m.in. MATLAB, Neuromore, OpenVIBE, LabStreamingLayer oraz BrainBay.

¹⁰ASCII (ang. American Standard Code for Information Interchange) – siedmiobitowy system służący do kodowania znaków.

¹¹Pomimo, że sama biblioteka napisana jest w C/C++, dodano nakładkę na język C++ w celu zapewnienia wysokopoziomowej warstwy abstrakcji.

ROZDZIAŁ 3

Projekt wirtualnej klawiatury

3.1. Założenia projektowe

3.2. Wybór narzędzi

3.2.1. Urządzenia rejestrujące

Wybierając urządzenie rejestrujące poszukiwano urządzenia, które (1) jest nieinwazyjne, (2) posiada rozwinięte SDK oraz bazę przykładowych aplikacji, (3) zapewnia sprzętowe wsparcie w zakresie detekcji komend mentalnych, (4) jest przystępne cenowo – kosztuje poniżej 500 \$. Dodatkową zaletą urządzenia, aczkolwiek niewymaganą do realizacji niżej opisanej pracy, byłaby (6) możliwość rejestracji dodatkowych sygnałów, na przykład przy użyciu akcelerometru. Wyboru dokonywano spośród urządzeń omówionych w rozdziale 2 na stronie 25.

W przypadku OpenBCI Ultracortex Mark IV, jednym z jego mankamentów jest wysoka cena – nawet w przypadku zakupu najtańszego wariantu, a więc hełmu do samodzielnego druku oraz montażu wraz z układem Ganglion Board, cena wynosiła 500 \$. Po doliczeniu do tej kwoty wymaganych elektrod cena znacznie wzrasta. W przypadku oferowanego przez firmę OpenBCI Starter Kitu, który zawiera wszystkie wymagane peryferiale, cena wynosi blisko 950 \$. Samodzielność montażu w odczuciu autora pracy jest ryzykownym posunięciem w przypadku tak delikatnych oraz precyzyjnych urządzeń, tym bardziej że nie jest to standardowy model sprzedawy tej gamy urządzeń. Niewątpliwą zaletą urządzeń OpenBCI jest ich otwartośródłowość – oprogramowanie jest dostępne na serwisie GitHub. Inną zaletą jest jego duża popularność oraz integracja z wieloma programami do analizy danych, jak na przykład MATLAB.

Urządzenia Muse 2 oraz MindWave Mobile 2 w odczuciu autora są narzędziami mało precyzyjnymi, nie nadającymi się do wykorzystania w celach badawczych. Ich zaletami jest łatwość zakładania, niska cena oraz smukłość, która prawdopodobnie pozwala na długie sesje bez odczuwania dyskomfortu związanego z naciskiem urządzenia. Wadą

Muse 2 jest brak SDK dla programistów. Wadą MindWave Mobile 2 jest liczba elektrod rejestrujących – urządzenie jest wyposażone w wyłącznie jedną.

Emotiv Insight oraz EPOC+ są bardzo popularne wśród osób zajmujących się tematyką BCI. Za pomocą rozbudowanego API pozwalają na detekcję nie tylko aktywności mózgu w poszczególnych pasmach, ale również komend mentalnych oraz mimiki. Ze względu na wykorzystywany protokół komunikacyjny, są uniwersalne pod względem platformy programistycznej oraz języka programowania. Ich największym mankamentem jest brak darmowego dostępu do surowych danych EEG – żeby je uzyskać trzeba wykupić licencję. Urządzenie EPOC+ charakteryzuje się lepszymi parametrami niż Insight, jednak jest od niego droższe. Inną jego wadą jest rodzaj czujników; EPOC+ używa nasączanych solą fizjologiczną, podczas kiedy czujniki w Insight są wykonane z półsuchego polimeru.

Ostatecznie zakupiono urządzenie Emotiv Insight. Nabyto najnowszą wersję urządzenia; premiera modelu odbyła się w maju 2019 roku. Niniejsza praca jest jednym z pierwszych projektów powstających na jego nowej odsłonie. Głównym czynnikiem przemawiającym na jego korzyść był dostęp do zaawansowanego API, które dobrze wpasowuje się w założenia pracy. Urządzenie posiada również atrakcyjną cenę; w opinii autora spośród omówionych modeli Emotiv Insight zapewnia najlepszy stosunek ceny do oferowanych możliwości.

3.2.2. Język programowania

Wybierając język programowania poszukiwano języka, który (1) jest językiem wysokiego poziomu, (2) jest językiem obiektowym, (3) umożliwia łatwe tworzenie interfejsu użytkownika, (4) posiada kompleksową dokumentację, (5) charakteryzuje się potencjałem przyszłego rozwoju oraz (6) dużą popularnością.

Języki wysokiego poziomu ułatwiają proces tworzenia oprogramowania, zwiększając czytelność kodu oraz poziom jego abstrakcji. Pozwalają na zdystansowanie się od warstwy sprzętowej komputera oraz większe skupienie się na aspektach związanych z logiką programu.

Języki obiektowe ułatwiają tworzenie dużych aplikacji. Programuje się w nich z użyciem obiektów, które stanowią instancje klas, które z kolei są definicją zmiennych, pól oraz metod dla obiektów danego typu. Wśród paradygmatów programowania obiektowego możemy wyróżnić abstrakcję, hermetyzację, polimorfizm oraz dziedziczenie.

Interfejs użytkownika umożliwia osobie użytkującej system na interakcję z oprogramowaniem. Wybrany język programowania powinien mieć zapewnioną łatwość tworzenia graficznych interfejsów; ich tworzenie powinno być możliwe natywnie, bez konieczności używania zewnętrznych bibliotek.

Język powinien mieć kompleksową oraz dobrze sformułowaną dokumentację. Dokumentacja techniczna stanowi źródło częstych odniesień w procesie powstawania oprogramowania, a zatem powinna być łatwo dostępna i umożliwiać szybkie odnajdywanie w niej potrzebnych informacji.

Potencjał przyszłego rozwoju pozwoli autorowi na wykorzystanie umiejętności zdobytych w trakcie realizacji niniejszej pracy w przyszłym życiu zawodowym. Uwzględnienie

tego kryterium przy wyborze danej technologii stanowi dobrą formę motywacji, która jest kluczowa do sprawnej realizacji pracy.

Używając języków o dużej popularności znacznie łatwiej jest posiłkować się serwisami dla programistów, takimi jak na przykład Stack Overflow. Dzięki swojej zaangażowanej społeczności, ułatwiają one proces rozwiązywania ewentualnych problemów, które mogą wystąpić w trakcie tworzenia oprogramowania.

Wśród wstępnie wyselekcjonowanych języków programowania znalazły się języki C++, C#, Java oraz JavaScript.

JavaScript został wyeliminowany jako pierwszy, ze względu na fakt, iż interpretacja kodu w nim tworzonego jest zależna od przeglądarki internetowej. Wymusza to testowanie oprogramowania na różnych wersjach przeglądarek, co w efekcie wydłuża czas powstawania aplikacji. Inną wadą JavaScript jest brak dostępu do zaawansowanych technik debugowania, do których dostęp istnieje w przypadku języków kompilowanych.

C++, pomimo wielu dostępnych materiałów oraz zaawansowanego narzędzia do tworzenia interfejsów użytkownika w postaci Qt, został wykluczony ze względu na brak jego znajomości przez autora pracy.

Dokonując ostatecznego wyboru pomiędzy C# oraz Javą, zdecydowano się zrealizować aplikację w języku C#. Autor pracy posiada większe doświadczenie w pracy z tym językiem, przez co realizacja w nim oprogramowania będzie w większym stopniu pozbacona antywzorców oraz wykonana w zgodzie z ogólnie przyjętymi standardami.

Wybranie języka C# wiąże się również z wyborem technologii tworzenia interfejsu graficznego; wybór dokonywano spośród Windows Forms (WinForms), Windows Presentation Foundation (WPF) oraz Universal Windows Platform (UWP). Zdecydowano się skorzystać z WPF ze względu na dodatkowe możliwości jakie oferuje pod kątem dostosowywania interfejsu użytkownika w odniesieniu do WinForms oraz brakiem ograniczeń, którymi charakteryzują się aplikacje uniwersalne[27].

3.2.3. Środowisko programistyczne

Najpopularniejszymi środowiskami programistycznymi do języka C# są Visual Studio, Rider oraz Visual Studio Code.

Zarówno Visual Studio jak i Rider są bardzo zaawansowanymi środowiskami. Oba programy posiadają funkcjonalności usprawniające tworzenie kodu, jego debugowanie, integrację testów oraz zarządzanie projektem, co czyni je niezwykle potężnymi narzędziami do pracy z językiem C#. W odczuciu autora główne różnice sprowadzają się do dwóch cech:

1. Visual Studio posiada darmową wersję Community, podczas gdy Rider, pomijając miesięczną wersję trial, wymaga zakupienia licencji,
2. Rider zapewnia znacznie więcej funkcjonalności dotyczących inspekcji kodu, czyli wykrywania oraz zastępowania jego fragmentów w celu ich uproszczenia lub uniknięcia potencjalnych błędów[25].

Visual Studio Code, pomimo iż z definicji jest edytorem kodu, a nie zintegrowanym

środowiskiem programistycznym, posiada wiele funkcjonalności pełnoprawnego IDE. Posiada między innymi wsparcie dla debugowania kodu, wersjonowania oprogramowania, uzupełniania kodu oraz kolorowania składni. Jego możliwości mogą być powiększane przez obszerną bazę rozszerzeń. Do jego zalet zależy znaczna szybkość, przejrzysty interfejs oraz cross-platformowość. Wadami narzędzi są niskie możliwości w zakresie inspekcji kodu oraz debugowania. VS Code jest darmowe.

Ostatecznie zdecydowano się na zrealizowanie projektu, wykorzystując do tego celu Visual Studio. Rider został odrzucony ze względu na konieczność zakupienia licencji oraz jego krótki okres obecności na rynku, przez co opinie na jego temat mogą nie być obiektywne. Visual Studio Code nie zostało wybrane ze względu na swoje nikkie możliwości w zakresie refaktoryzacji kodu.

3.2.4. System kontroli wersji

Jako system kontroli wersji wybrano Git. Opracowana aplikacja jest hostowana w prywatnym, niedostępnym dla osób postronnych, repozytorium na serwisie GitHub

3.3. Omówienie aplikacji

3.3.1. Struktura kodu źródłowego

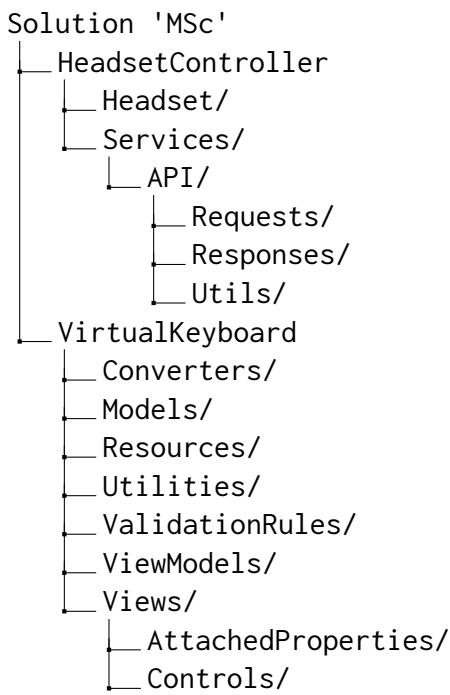
Rozwiązanie (ang. Solution) zostało podzielone na dwa projekty: HeadsetController oraz VirtualKeyboard. Wydzielenie osobnych projektów odseparowało logikę związaną z obsługą samego hełmu oraz z wirtualną klawiaturą – umożliwia to dołączanie projektu HeadsetController do innych aplikacji, nawet tych niewykonanych w języku C#, bez konieczności ingerencji w jego kod. Struktura rozwiązania w postaci drzewa została przedstawiona na rysunku 3.1 na sąsiedniej stronie.

HeadsetController jest biblioteką służącą do komunikacji z urządzeniem. Jest projektem o typie wynikowym DLL¹ (output type: class library). Nie stanowi samodzielnej aplikacji; jest przeznaczony do bycia dołączonym do innych projektów. W projekcie znajdują się dwa główne foldery: Headset oraz Services.

Do folderu Headset należą klasy Headset.cs oraz Insight.cs. Headset.cs jest klasą abstrakcyjną realizującą niskopoziomową komunikację z urządzeniami Emotiv – zajmuje się przetwarzaniem danych otrzymanych protokołem WebSocket, a następnie, na podstawie zawartości otrzymanej wiadomości, wywoływaniem odpowiednich eventów. Insight.cs stanowi programową reprezentację hełmu Emotiv Insight; umożliwia dostęp do jego parametrów, na przykład poziomu naładowania, jakości połączenia poszczególnych elektrod lub siły komend mentalnych. Dziedziczy po klasie Headset.cs.

W folderze Services znajdują się klasy JsonParser.cs oraz WebSocket.cs, które stanowią klasy opakowujące (ang. wrappers) na operacje kolejno na formacie JSON oraz protokole WebSocket. Dzięki zastosowaniu takiego podejścia, wewnętrzna implementa-

¹DLL (ang. Dynamic-link library) – biblioteka łączona dynamicznie; rodzaj biblioteki łączonej z programem dopiero w trakcie jego wykonywania.



Rysunek 3.1. Struktura rozwiązania przedstawiona w postaci drzewa

Źródło: Opracowanie własne

cja tych klas jest ukryta przed użytkownikami biblioteki. Dla programisty dostępne są wyłącznie wysokopoziomowe metody niezbędne do pracy z urządzeniem, co wpisuje się w zasadę hermetyzacji. W tym folderze znajduje się również folder API, który zawiera trzy podkatalogi: Requests, Responses oraz Utils. Pierwsze dwa z nich zawierają definicję zapytań oraz odpowiedzi, pogrupowanych w dalsze foldery zgodnie z nomenklaturą zawartą w dokumentacji protokołu komunikacyjnego urządzenia. Folder Utils zawiera klasę Enums.cs, w której umieszczone są typy wyliczeniowe wykorzystywane do komunikacji.

Projekt VirtualKeyboard jest aplikacją Windows (output type: Windows application) wykorzystującą strukturę interfejsu Windows Presentation Foundation (WPF). Zawiera 7 głównych folderów: Converters, Models, Resources, Utilities, ValidationRules, ViewModels oraz Views.

Katalog Converters zawiera implementacje interfejsów IValueConverter oraz IMultiValueConverter. Są w nim zawarte konwertery umożliwiające stosowanie niestandardowej logiki do tworzenia powiązań między interfejsem użytkownika, a właściwościami (ang. properties) w aplikacji. Przykładem zaimplementowanego konwertera może być BooleanToVisibilityConverter.cs, który zwraca wartość typu wyliczeniowego Visibility na podstawie przekazanej zmiennej typu boolean. I tak, dla parametru **true** zwraca wartość **Visibility.Visible**, a dla **false** – **Visibility.Hidden**.

Folder Models zawiera klasy odpowiedzialne za logikę biznesową aplikacji. Jako że przeważająca część logiki jest umieszczona w klasie Insight.cs znajdującej się w projekcie HeadsetController, w tym folderze umieszczona jest wyłącznie klasa Settings.cs. Przechowuje ona ustawienia dotyczące progów aktywacji dla poszczególnych komend

mentalnych, czasu skupienia wymaganego do ich aktywacji oraz wartość określającą czy włączony został tryb offline aplikacji. Klasa jest deserializowana z pliku settings.json wraz ze startem aplikacji oraz serializowana do niego podczas jej zamknięcia. Dzięki zastosowaniu mechanizmu serializacji użytkownik nie traci ustawień poprzedniej sesji.

Folder Resources zawiera graficzne zasoby wykorzystywane w aplikacji. Przechowywana jest tu między innymi ikona aplikacji – keyboard.ico.

W katalogu Utilities znajduje się klasa SettingsSerializer.cs, która odpowiada za serializację oraz deserializację klasy Settings.cs oraz jej zapis/odczyt z pliku. Plik wynikowy settings.json zostaje umieszczony w folderze, w którym znajduje się aplikacja.

Folder ValidationRules zawiera klasę NotEmptyValidationRule.cs, która jest wykorzystywana do potwierdzenia poprawności wprowadzonych przez użytkownika ustawień połączenia z hełmem Emotiv Insight.

Katalog ViewModels zawiera tak zwane ViewModels, czyli klasy implementujące interfejs INotifyPropertyChanged, które stanowią centrum wykorzystywanego w aplikacji wzorca MVVM². Za pomocą mechanizmu komend oraz wiązania danych (ang. data binding) są one połączone z widokami.

Ostatni katalog, Views, zawiera definicje widoków w postaci plików XAML³. Zawarte są w nim również foldery AttachedProperties, w których przechowywane są właściwości rozszerzające zdefiniowane kontrolki, oraz Controls, w którym znajduje się definicja stworzonej przez autora pracy kontrolki KeyView, która jest składową opracowanej klasy.

3.3.2. Algorytm działania

3.3.3. Trening detekcji komend mentalnych

Poprzez swoje API Emotiv Insight umożliwia wykrywanie maksymalnie do 5 komend mentalnych, stanu neutralnego oraz wybranych czterech spośród następujących trzynastu wyobrażeń: pchnięcia, przyciągnięcia, uniesienia, opuszczenia, przesunięcia w lewo, przesunięcia w prawo, obrotu zgodnie ze wskazówkami zegara, obrotu przeciwko zegarowi, obrotu zegara, obrotu w przód, obrotu w tył, obrotu w lewo, obrotu w prawo oraz zniknięcia. Dodatkowo wspomaga detekcję stanów emocjonalnych, to jest ekscytacji, długotrwałej ekscytacji, stresu, zaangażowania, odpreżenia, zainteresowania oraz skupienia. Spośród mimiki umożliwia wykrywanie mrugnięcia, puszczenia oczka, zmarszczenia brwi, uniesienia brwi, uśmiechu i zaciśnięcia zębów.

Wykorzystując aplikację EmotivBCI możliwe jest trenowanie detekcji poszczególnych komend mentalnych w czasie rzeczywistym. Trening jest interaktywny; użytkownik, obserwując wirtualny sześcian, wyobraża sobie kolejne komendy, a system rejestruje ak-

²MVVM (ang. Model–View–ViewModel) – wzorzec architektury oprogramowania zapewniający separamcję warstw UI oraz biznesowej; silnie zakorzeniony w aplikacjach WPF.

³XAML (ang. Extensible Application Markup Language) – oparty na XML język znaczników wykorzystywany do opisu interfejsu użytkownika w między innymi aplikacjach Windows Presentation Framework.

tywność mózgu związaną z danym wyobrażeniem. W miarę postępu oraz nasilania skupienia na danej akcji sześciyan wykonuje wyobrażoną czynność, na przykład obraca się w prawo lub znika. Trening detekcji mimiki, podobnie jak komend mentalnych, jest również interaktywny – użytkownik obserwuje postęp na wirtualnym awatarze.

Istotną kwestią jest wybór odpowiednich poleceń mentalnych do obsługi wirtualnej klawiatury. Intuicyjność interakcji z systemem pozwoli użytkownikowi na szybsze przy- swojenie zasady sterowania oraz zniweluje ilość błędów związanych z myleniem poleceń. Opracowany projekt wymaga pięciu komend: przesunięcia selekcji w góre, w dół, w prawo, w lewo oraz akceptację (*wciśnięcie*) aktualnie oznaczonego klawisza. O ile w przypadku przesunięcia selekcji dobr komend mentalnych wydaje się oczywisty (są to polecenia *unesienie*, *opuszczenie*, *przesunięcie w lewo* i *przesunięcie w prawo*), to komenda akceptacji wyboru wymaga głębszej analizy; czy powinno to być *pchnięcie*, symulujące wciśnięcie klawisza klawiatury, a może *przyciągnięcie*, czyli zwolnenie klawisza i przejście do wyboru kolejnej litery? Należy mieć również na uwadze, iż zwiększoną ilość komend możliwych do wykrywania będzie prowadziła do powiększenia stopy błędu detekcji. Ponieważ w niniejszej aplikacji akceptacja selekcji jest kluczowym poleceniem, postanowiono wykorzystać do niego detekcję wyrazów twarzy. Zdecydowano, iż będzie za nią odpowiadać *unesienie brwi*, które osiągało najkorzystniejszy stosunek poprawnych do omyłkowych klasyfikacji spośród dostępnych możliwości detekcji.

3.3.4. Komunikacja z urządzeniem

3.3.5. Proces decyzyjny

3.4. Omówienie interfejsu użytkownika

3.4.1. Zakładka *Virtual Keyboard*

3.4.2. Zakładka *Messenger*

3.4.3. Zakładka *About*

3.4.4. Zakładka *Connection*

3.4.5. Zakładka *Settings*

ROZDZIAŁ 4

Badania opracowanego systemu

4.1. Badanie wpływu zakłóceń

4.2. Badanie wpływu parametrów algorytmu

Zakończenie

TODO

Bibliografia

- [1] Bashir I. M.: A Brief Review of Brain Signal Monitoring Technologies for BCI Applications: Challenges and Prospects. *Journal of Bioengineering & Biomedical Science*, t. 04, nr 01, 2014, DOI: 10.4172/2155-9538.1000128.
- [2] Bashivan P., Rish I., Heisig S.: Mental state recognition via wearable EEG. *CoRR*, t. abs/1602.00985, 2016, URL: <http://arxiv.org/abs/1602.00985>.
- [3] Benabid A. L. i in.: Deep brain stimulation: BCI at large, where are we going to?, *Brain Machine Interfaces: Implications for Science, Clinical Practice and Society, Progress in Brain Research*, t. 194, rozd. 5, s. 71–82, Elsevier, 2011, DOI: 10.1016/B978-0-444-53815-4.00016-9.
- [4] Blankertz B. i in.: The Berlin Brain–Computer Interface: Non-Medical Uses of BCI Technology. *Frontiers in Neuroscience*, t. 4, s. 198, 2010, DOI: 10.3389/fnins.2010.00198.
- [5] Boi F. i in.: A Bidirectional Brain-Machine Interface Featuring a Neuromorphic Hardware Decoder. *Frontiers in Neuroscience*, t. 10, grud. 2016, DOI: 10.3389/fnins.2016.00563.
- [6] Cegielska A., Olszewski M.: Nieinwazyjny interfejs mózg–komputer do zastosowań technicznych. *Pomiary Automatyka Robotyka*, t. R. 19, nr 3, s. 5–14, 2015.
- [7] Clerc M., Bougrain L. i Lotte F., red.: *Brain-Computer Interfaces 1: Foundations and Methods*, John Wiley & Sons, Inc., Hoboken, NJ, USA, lip. 2016, DOI: 10.1002/9781119144977.
- [8] Clerc M., Bougrain L. i Lotte F., red.: *Brain-Computer Interfaces 2: Technology and Applications*, John Wiley & Sons, Inc., Hoboken, NJ, USA, sierp. 2016, DOI: 10.1002/9781119332428.
- [9] Coyle D., red.: *Brain-Computer Interfaces: Lab Experiments to Real-World Applications*, Elsevier, Netherlands, 2016.
- [10] Dhiman R., Saini J., Mittal A.: Artifact removal from EEG recordings – An overview, *National Conference on Computational Instrumentation NCCI-2010*, s. 62–66, Chandigarh, India, mar. 2010.
- [11] Emotiv: *Develop with Emotiv*, URL: <https://www.emotiv.com/developer/> (dostęp: 08.04.2019).
- [12] Emotiv: *Emotiv EPOC+ 14 Channel Mobile EEG*, URL: <https://www.emotiv.com/product/emotiv-e poc-14-channel-mobile-eeg/> (dostęp: 21.04.2019).
- [13] Emotiv: *Emotiv Insight 5 Channel Mobile EEG*, URL: <https://www.emotiv.com/product/emotiv-insight-5-channel-mobile-eeg/> (dostęp: 21.04.2019).
- [14] Emotiv: *Emotiv PRO*, URL: <https://www.emotiv.com/emotivpro/> (dostęp: 08.04.2019).

- [15] Emotiv: Headsets comparison chart, URL: <https://www.emotiv.com/comparison/> (dostęp: 04.04.2019).
- [16] Finisguerra A., Borgatti R., Urgesi C.: Non-invasive Brain Stimulation for the Rehabilitation of Children and Adolescents With Neurodevelopmental Disorders: A Systematic Review. *Frontiers in Psychology*, t. 10, lut. 2019, DOI: 10.3389/fpsyg.2019.00135.
- [17] Ghane-Motlagh B., Sawan M.: Design and Implementation Challenges of Micro-electrode Arrays: A Review. *Materials Sciences and Applications*, t. 04, nr 08, s. 483–495, 2013, DOI: 10.4236/msa.2013.48059.
- [18] Graimann B., Pfurtscheller G. i Allison B., red.: *Brain-Computer Interfaces: Revolutionizing Human-Computer Interaction*, Springer Berlin Heidelberg, Berlin, Heidelberg, 2010, DOI: 10.1007/978-3-642-02091-9.
- [19] Hassanien A. E. i Azar A. T., red.: *Brain-Computer Interfaces: Current Trends and Applications*, Springer International Publishing, 2015, DOI: 10.1007/978-3-319-10978-7.
- [20] Interaxon Inc. *Compare Muse Devices*, URL: <https://choosemuse.com/product-comparison/> (dostęp: 23.04.2019).
- [21] Interaxon Inc. *Introducing Muse 2*, URL: <https://choosemuse.com/muse-2/> (dostęp: 23.04.2019).
- [22] Interaxon Inc. *Muse developer*, URL: <https://choosemuse.com/development/> (dostęp: 23.04.2019).
- [23] Interaxon Inc. *Muse professional*, URL: <https://choosemuse.com/muse-professionals/> (dostęp: 23.04.2019).
- [24] Interaxon Inc. *What are the differences between Muse 2 and Muse the brain sensing headband?*, URL: <https://choosemuse.force.com/s/article/How-is-Muse-2-different-than-Muse-the-brain-sensing-headband?> (dostęp: 23.04.2019).
- [25] JetBrains: *JetBrains Rider vs Visual Studio (with and without ReSharper)*, URL: <https://www.jetbrains.com/rider/compare/rider-vs-visual-studio/> (dostęp: 03.08.2019).
- [26] Lotte F., Congedo M., Lécuyer A., Lamarche F., Arnaldi B.: A review of classification algorithms for EEG-based brain-computer interfaces. *Journal of Neural Engineering*, t. 4, nr 2, R1–R13, sty. 2007, DOI: 10.1088/1741-2560/4/2/r01.
- [27] Microsoft: *Choose your app platform*, mar. 2019, URL: <https://docs.microsoft.com/en-us/windows/apps/desktop/choose-your-platform> (dostęp: 03.08.2019).
- [28] Min B.-K., Marzelli M. J., Yoo S.-S.: Neuroimaging-based approaches in the brain-computer interface. *Trends in Biotechnology*, t. 28, nr 11, s. 552–560, 2010, DOI: 10.1016/j.tibtech.2010.08.002.

- [29] Nam C. S., Nijholt A., Lotte F.: *Brain-Computer Interfaces Handbook: Technological and Theoretical Advances*, CRC Press, Inc., Boca Raton, FL, USA, 2018.
- [30] NeuroSky, Inc. *MindWave Mobile 2 - Brainwave Sensing Headset*, URL: <https://store.neurosky.com/pages/mindwave> (dostęp: 24.04.2019).
- [31] NeuroSky, Inc. *NeuroSky Developer*, URL: <http://developer.neurosky.com/docs/doku.php> (dostęp: 24.04.2019).
- [32] NeuroSky, Inc. *NeuroSky Research Tools*, URL: <https://store.neurosky.com/products/mindset-research-tools> (dostęp: 24.04.2019).
- [33] Nijholt A.: BCI for Games: A ‘State of the Art’ Survey, *Entertainment Computing - ICEC 2008*, s. 225–228, Springer Berlin Heidelberg, Berlin, Heidelberg, 2009.
- [34] Onishi A., Natsume K.: Overlapped Partitioning for Ensemble Classifiers of P300-Based Brain-Computer Interfaces. *PLOS ONE*, t. 9, nr 4, kw. 2014, DOI: 10.1371/journal.pone.0093045.
- [35] OpenBCI: *Brainflow*, URL: <https://github.com/OpenBCI/brainflow> (dostęp: 04.06.2019).
- [36] OpenBCI: *Cyton + Daisy Biosensing Boards (16-channels)*, URL: <https://shop.openbci.com/collections/frontpage/products/cyton-daisy-biosensing-boards-16-channel> (dostęp: 29.04.2019).
- [37] OpenBCI: *Cyton Biosensing Board (8-channels)*, URL: <https://shop.openbci.com/collections/frontpage/products/cyton-biosensing-board-8-channel> (dostęp: 29.04.2019).
- [38] OpenBCI: *Ganglion Board (4-channels)*, URL: <https://shop.openbci.com/collections/frontpage/products/pre-order-ganglion-board> (dostęp: 29.04.2019).
- [39] OpenBCI: *The OpenBCI GUI*, URL: https://github.com/OpenBCI/OpenBCI_GUI (dostęp: 04.06.2019).
- [40] OpenBCI: *Ultracortex Mark IV*, URL: <https://docs.openbci.com/Headware/01-Ultracortex-Mark-IV> (dostęp: 28.04.2019).
- [41] OpenBCI: *Ultracortex Mark IV EEG Headset*, URL: <https://shop.openbci.com/products/ultracortex-mark-iv> (dostęp: 28.04.2019).
- [42] Paszkiel S.: Wykorzystanie metody PCA i ICA do analizy sygnału EEG w kontekście usuwania zakłóceń. *Pomiary Automatyka Kontrola*, t. R. 59, nr 3, s. 204–207, 2013.
- [43] Rao R. P.: *Brain-Computer Interfacing: An Introduction*, Cambridge University Press, New York, NY, USA, 2013.
- [44] *Technical specifications, validation, and research use*, InteraXon Inc., kw. 2017.
- [45] Vaibhav G.: *Brain-Computer Interfacing for Assistive Robotics*, Academic Press, San Diego, 2015, DOI: 10.1016/C2013-0-23408-5.

- [46] Wander J. D., Rao R. P.: Brain–computer interfaces: a powerful tool for scientific inquiry. *Current Opinion in Neurobiology*, t. 25, s. 70–75, kw. 2014, DOI: 10.1016/j.conb.2013.11.013.
- [47] Wolpaw J., Wolpaw E.: *Brain-Computer Interfaces: Principles and Practice*, Oxford University Press, USA, 2012.

Spis tabel

2.1. Parametry Emotiv Insight	26
2.2. Parametry Emotiv EPOC+	29
2.3. Parametry Muse oraz Muse 2	31
2.4. Parametry MindWave Mobile 2	32
2.5. Parametry Ultracortex Mark IV w połączeniu z kompatybilnymi układami	36

Spis rysunków

1.1.	Homunkulus ruchowy Penfielda	10
1.2.	Umiejscowienie elektrod wykorzystywanych w inwazyjnych BCI	12
1.3.	Sposoby nieinwazyjnej akwizycji aktywności mózgu	14
1.4.	Rodzaje artefaktów występujących w sygnałach EEG	17
1.5.	Struktura interfejsu opartego o potencjał P300	20
1.6.	Zależność między stopniem skupienia, a stopą błędu	23
2.1.	Hełm Emotiv Insight	25
2.2.	Rozmieszczenie sensorów w hełmie Emotiv Insight	26
2.3.	Hełm Emotiv EPOC+	28
2.4.	Rozmieszczenie sensorów w hełmie Emotiv EPOC+	28
2.5.	Opaska Muse 2	30
2.6.	Rozmieszczenie sensorów w opasce Muse	30
2.7.	Hełm MindWave Mobile 2	32
2.8.	Hełm Ultracortex Mark IV	34
2.9.	Rozmieszczenie sensorów w hełmie Ultracortex Mark IV	34
2.10.	OpenBCI Ganglion Board	35
2.11.	OpenBCI Cyton Board	35
2.12.	OpenBCI Cyton + Daisy Board	36
3.1.	Struktura rozwiązania przedstawiona w postaci drzewa	43

Spis kodów źródłowych