

Adam Baniuszewicz

nr albumu: 33816

kierunek studiów: Teleinformatyka

forma studiów: studia stacjonarne

specjalność: Sieci teleinformatyczne i systemy mobilne

**ALGORYTMY POLECEŃ MENTALNYCH W INTERFEJSACH
MÓZG-KOMPUTER**

**ALGORITHMS OF MENTAL COMMANDS IN BRAIN-COMPUTER
INTERFACES**

Praca dyplomowa magisterska

napisana pod kierunkiem:

dr. inż. Roberta Krupińskiego

Katedra Przetwarzania Sygnałów i Inżynierii Multimedialnej

Data wydania tematu pracy: 01.11.2018 r.

Data złożenia pracy: TODO r.

Szczecin, TODO

OŚWIADCZENIE AUTORA PRACY DYPLOMOWEJ

Oświadczam, że praca magisterska pn.

„Algorytmy poleceń mentalnych w interfejsach mózg–komputer”

napisana pod kierunkiem:

dr. inż. Roberta Krupińskiego

jest w całości moim samodzielnym autorskim opracowaniem sporządzonym przy wykorzystaniu wykazanej w pracy literatury przedmiotu i materiałów źródłowych.

Złożona w dziekanacie Wydziału Elektrycznego treść mojej pracy dyplomowej w formie elektronicznej jest zgodna z treścią w formie pisemnej.

Oświadczam ponadto, że złożona w dziekanacie praca dyplomowa ani jej fragmenty nie były wcześniej przedmiotem procedur procesu dyplomowania związanych z uzyskaniem tytułu zawodowego w uczelniach wyższych.

.....
podpis dyplomanta

Szczecin, dn. TODO r.

Streszczenie pracy

TODO

Słowa kluczowe

BCI, Elektroencefalografia

Abstract

TODO

Keywords

BCI, Electroencephalography

Spis treści

Wykaz ważniejszych oznaczeń i skrótów	6
Wprowadzenie	7
1. Wstęp do tematyki interfejsów mózg-komputer	9
1.1. Czym jest BCI	9
1.2. Rodzaje BCI	9
1.2.1. Inwazyjne	9
1.2.2. Nieinwazyjne	9
1.2.3. Stymulujące oraz dwukierunkowe	9
1.3. Przetwarzanie sygnałów	9
1.3.1. Usunięcie szumów	9
1.3.2. Ekstrakcja cech	11
1.3.3. Klasyfikacja sygnałów	12
1.4. Przegląd potencjalnych zastosowań	14
1.4.1. Interfejs komunikacyjny	14
1.4.2. Sterowanie wózkiem inwalidzkim	15
1.4.3. Rehabilitacja	16
1.4.4. Nadzór skupienia	16
1.4.5. Gry komputerowe	18
2. Charakterystyka wybranych urządzeń komercyjnych	19
2.1. Emotiv Insight	19
2.2. Emotiv EPOC+	22
2.3. Muse/Muse 2	22
2.4. MindWave Mobile 2	25
2.5. OpenBCI Ultracortex Mark IV	26
3. Projekt systemu	33
4. Badania opracowanego systemu	35
4.1. Badanie wpływu zakłóceń	35
4.2. Badanie wpływu parametrów algorytmu	35
Zakończenie	36
Bibliografia	37
Spis tabel	40
Spis rysunków	41
Spis kodów źródłowych	42

Wykaz ważniejszych oznaczeń i skrótów

API	Application programming interface — Interfejs programistyczny aplikacji
BCI	Brain-computer interface — Interfejs mózg-komputer
EEG	Elektroencefalografia
EKG	Elektrokardiografia
EMG	Elektromiografia
EOG	Elektrookulografia
SDK	Software development kit — Zestaw narzędzi do tworzenia oprogramowania

Wprowadzenie

TODO

Cel pracy

TODO

Zakres pracy

TODO

ROZDZIAŁ 1

Wstęp do tematyki interfejsów mózg-komputer

1.1. Czym jest BCI

1.2. Rodzaje BCI

1.2.1. Inwazyjne

Interfejsy pozwalające na pozyskiwanie sygnałów bezpośrednio z komórek mózgowych nazywane są inwazyjnymi. W celu *zainstalowania* wymagają one operacji, w której część czaszki jest usuwana, elektroda lub implant jest umieszczany w mózgu, a następnie czaszka jest przytwierdzana z powrotem[34]. Technika inwazyjna stosowana jest najczęściej w badaniach przeprowadzanych z wykorzystaniem zwierząt[34]. W przypadku ludzi pomiary inwazyjne pobierane są najczęściej w warunkach klinicznych, podczas operacji mózgu lub monitorowania pacjenta bezpośrednio przed operacją.

Interfejsy inwazyjne charakteryzują się najwyższą jakością pozyskanych sygnałów. Spowodowane jest to brakiem zniekształceń sygnałów powodowanych przez czaszkę, która ma 20÷80 krotnie mniejszą przewodność[5].

1.2.2. Nieinwazyjne

1.2.3. Stymulujące oraz dwukierunkowe

1.3. Przetwarzanie sygnałów

1.3.1. Usunięcie szumów

Sygnały EEG charakteryzują się bardzo niskim współczynnikiem SNR^1 [13]. Z tego powodu przed przystąpieniem do ich analizy należy najpierw usunąć z nich możliwie największą

¹SNR (*ang.* signal-to-noise ratio) – stosunek sygnału do szumu

ilość artefaktów. Przykładowe przebiegi zakłóceń zostały pokazane na rysunku 1.1 na sąsiedniej stronie.

Pierwszym typem zakłóceń są zakłócenia pochodzące ze środowiska, w którym jest rejestrowany sygnał EEG. Możemy do nich zaliczyć między innymi zakłócenia od sieci energetycznej oraz elektroniki (komputerów, telefonów, routerów Wi-Fi i tym podobnych). Najprostszym sposobem minimalizacji ich wpływu na sygnał wyjściowy jest eliminacja źródeł zakłóceń – przeprowadzenie akwizycji sygnałów z dala od miast, usunięcie zbędnych urządzeń z otoczenia, zastąpienie, o ile to możliwe, zasilania niezbędnych urządzeń prądem przeniennym na rzecz prądu stałego. Innym sposobem jest wykorzystanie klatki Faradaya.

Drugim typem zakłóceń są tak zwane zakłócenia fizjologiczne. Powstają one na skutek ruchu ciała lub innych fluktuacji potencjałów bioelektrycznych. Ich źródła są niemożliwe do wyeliminowania. Typowymi przykładami takich zakłóceń są sygnały EOG, EMG oraz EKG. W szczególności dwa pierwsze, z racji małej odległości od miejsca akwizycji sygnałów EEG, mają duży wpływ na SNR. Wpływ EOG oraz EMG można zminimalizować poprzez uniknięcie nadmiernego mrugania, ruchu oczu oraz napinania mięśni.

Typowymi technikami usunięcia artefaktów z sygnału EEG są[34]:

Progowanie — jeżeli jakakolwiek charakterystyka sygnału EOG lub EMG przekracza zdefiniowany próg (*ang.* threshold), próbki sygnałów EEG w tej epoce zostają uznane za skażone i są odrzucane. Ten sposób może być zastosowany również dla akwizycji wyłącznie sygnałów EEG, jednak to podejście wymaga wstępnej kalibracji z użytkownikiem. Wadą tego rozwiązania jest utrata informacji zawartych w odrzuconych próbkach.

Filtracja — wycięcie z pobranego sygnału składowych o określonym paśmie częstotliwości przy użyciu filtru pasmowo-zaporowego. W celu przeprowadzenia filtracji należy przekształcić sygnał do dziedziny częstotliwości (na przykład przy użyciu FFT), wyciąć składowe o niepożądanym częstotliwości, a następnie przekształcić sygnał z powrotem do dziedziny czasu. Usunąć w ten sposób można między innymi zakłócenia sieci energetycznej² oraz artefakty EOG (około 1÷4 Hz). Filtrację należy stosować, tylko jeżeli podlegające jej składowe mają inną częstotliwość niż sygnały, które chcemy uzyskać.

Regresja liniowa — przy założeniu, iż szum sygnału EEG jest addytywny można sformułować zależność w postaci[34]:

$$EEG_i(t) = EEG_i^{true}(t) + K \times EOG(t)$$

gdzie $EEG_i^{true}(t)$ jest czystym sygnałem EEG pozyskanym z elektrody i w czasie t , $EOG(t)$ jest sygnałem EOG w czasie t , a K stałą, która może być estymowana. Posiadając estymację stałej K , na podstawie prostego przekształcenia możemy uży-

²W zależności od kraju zakłócenia te mogą występować w innym paśmie częstotliwości. W Europie jest to 50 Hz, ale na przykład w większości państw Ameryki Północnej częstotliwość sieci wynosi 60 Hz.


skać estymację czystego sygnału EEG w postaci:

$$EEG_i^{true}(t) = EEG_i(t) - K \times EOG(t)$$

Ten sposób trudniejszy do usunięcia artefaktów EMG, ponieważ pochodzą one z wielu źródeł (wielu grup mięśni) i wymagają opracowania bardziej skomplikowanego modelu.

Analiza składowych głównych — inaczej PCA (*ang.* Principal Component Analysis); polega na redukcji współczynników potrzebnych do opisu dużej liczby skorelowanych ze sobą zmiennych, przy jednoczesnym zachowaniu jak największej liczby składowych znajdujących się w sygnale właściwym. Umożliwia zmniejszenie ilości informacji zawartych w sygnale poprzez eliminację pewnych składowych zawierających artefakty[33]. PCA pozwala na usunięcie szumów związanych z EOG[34].

Analiza składowych niezależnych — inaczej ICA (*ang.* Independent Component Analysis); pozwala na estymację nieznanymi sygnałów źródłowych oraz ekstrakcję zakłóceń w celu ich późniejszej eliminacji[33]. ICA stosuje się w celu eliminacji zakłóceń EOG oraz EMG[34].



Rysunek 1.1. Rodzaje artefaktów występujących w sygnałach EEG

Źródło: [7]

1.3.2. Ekstrakcja cech

Celem ekstrakcji cech (*ang.* feature extraction) jest przekształcenie surowych danych EEG do postaci nadającej się do wykorzystania w procesie klasyfikacji sygnałów[36].

Cecha jest właściwością opisującą sygnał EEG[4]. Cechą podstawową sygnału jest jego bezpośredni pomiar[37], na przykład różnica potencjałów pomiędzy dwoma elektrodami w chwili t . Podstawowe cechy są zazwyczaj przedstawiane w postaci cech złożonych, które stanowią ich liniowe oraz nieliniowe kombinacje, stosunki lub miary statystyczne. W celu jak najdokładniejszej detekcji intencji użytkownika wiele cech jest pozyskiwanych jednocześnie; są one zazwyczaj grupowane w tak zwane wektory cech[4].

Przykładem wykorzystania ekstrakcji cech może być rozpoznanie wyobrażenia ruchu ręką – cechą używaną do detekcji jest moc pasma μ ($8\div 12$ Hz) oraz β ($16\div 24$ Hz)[4].

W interfejsach mózg–komputer najczęściej wykorzystywane są cechy opisujące sygnał[3]:

Przestrzennie — służą do przybliżonego wyznaczania źródeł sygnału[3].

Spektralnie — opisują moc sygnału w zależności od częstotliwości[4].

Czasowo — opisują zmianę sygnału w czasie.

Innymi cechami wykorzystywanymi w BCI są reprezentacje czasowo–częstotliwościowe sygnałów, transformacja Hilberta oraz parametry Hjortha[36].

Problem ekstrakcji cech został poruszony szerzej w literaturze [3, 4, 34, 36, 37].

1.3.3. Klasyfikacja sygnałów

Klasyfikatory służą do rozpoznawania wzorców w wektorach cech sygnałów EEG. Ich zadaniem jest przekształcenie aktywności mózgu w sygnały użyteczne dla komputera.

Wśród klasyfikatorów możemy wyróżnić między innymi:

Klasyfikator liniowy — algorytm dyskryminacyjny posługujący się funkcjami liniowymi w celu rozróżnienia poszczególnych klas[19]. Wśród tego rodzaju klasyfikatorów w BCI najczęściej wykorzystywane są LDA³ oraz SVM⁴[13].

LDA jest liniowym klasyfikatorem binarnym, który przy pomocy hiperpłaszczyzny rozdziela dane reprezentujące różne klasy[19]. Metoda jest stosunkowo prosta i posiada małą złożoność obliczeniową, przez co jest często stosowana w BCI. Jej wadą jest osiąganie słabych rezultatów klasyfikacji w przypadku złożonych, nieliniowych wektorów cech sygnałów EEG[13].

SVM, podobnie jak LDA, używa hiperpłaszczyzny w celu rozdzielenia poszczególnych klas. W przypadku SVM poszukiwana hiperpłaszczyzna powinna rozdzielać z maksymalnym marginesem dane należące do odrębnych klas. Metoda posiada dobre właściwości generalizacji oraz jest niewrażliwa na przetrenowanie[3].

Sieci neuronowe — wśród sieci neuronowych wykorzystywanych w BCI najczęściej zastosowanie znajduje MLP⁵[19].

³LDA (*ang.* linear discriminant analysis) – liniowa analiza dyskryminacyjna

⁴SVM (*ang.* support vector machine) – maszyna wektorów nośnych

⁵MLP (*ang.* multilayer perceptron) – wielowarstwowy perceptron

MLP składa się z kilku warstw neuronów: warstwy wejściowej, warstw ukrytych oraz warstwy wyjściowej. Wielowarstwowy perceptron jest wrażliwy na przetrenowanie, w szczególności w przypadku zaszumionych danych, takich jak sygnały EEG[13].

Innymi rodzajami sieci neuronowych wykorzystywanymi w BCI są między innymi LVQ, Fuzzy ARTMAP, RBF oraz BLRNN, ALN oraz PeGNC[19].

Naiwny klasyfikator bayesowski — jest klasyfikatorem probabilistycznym opartym na założeniu niezależności cech. Z tego powodu jest również zwany modelem cech niezależnych (*ang.* independent feature model). Rozpatrując klasyfikację jako zadanie przyporządkowania klasy do konkretnego wejścia na podstawie wektorów cech F_1, F_2, \dots, F_n , decyzję otrzymujemy poprzez wybranie klasy z największym prawdopodobieństwem:

$$P(C = i | F_1, \dots, F_n)$$

Na drodze przekształceń, korzystając z twierdzenia Bayesa, otrzymujemy prawdopodobieństwo w postaci:

$$P(C = i | F_1, \dots, F_n) = P(C = i)P(F_1 | C = i)P(F_2 | C = i) \dots P(F_n | C = i)$$

Mając równanie w tej postaci, wynik klasyfikacji otrzymujemy poprzez obliczenie prawdopodobieństwa dla każdej z klas, a następnie wybranie tej o największym prawdopodobieństwie[34].

Algorytm najbliższego sąsiada — klasa wyjściowa jest przydzielana na podstawie najbliższego sąsiada, który jest wyłaniany na przykład przy pomocy odległości euklidesowej między wektorami, danej wzorem[34]:

$$d_{x,y} = \sqrt{\sum_{n=1}^M (x_n - y_n)^2}$$

gdzie $d_{x,y}$ jest odległością między wektorami x oraz y .

Klasyfikacja algorytmem najbliższego sąsiada NN (*ang.* nearest neighbor) jest podatna na szum[34]. Z tego powodu często jest zastępowana bardziej odporną odmianą w postaci algorytmu k najbliższych sąsiadów k -NN (*ang.* k nearest neighbors), w którym klasa jest przyporządkowywana na podstawie klasyfikacji k najbliższych sąsiadów.

W celu poprawy klasyfikacji można zastosować połączenie kilku różnych algorytmów. Ostateczne przyporządkowanie do konkretnej klasy następuje wtedy na drodze wzmacniania, głosowania lub nakładania.

Wzmacnianie (*ang.* boosting) wykorzystuje klasyfikatory połączone w kaskadę. Każdy klasyfikator stara się wyeliminować błąd wprowadzony przez poprzednie. Ten sposób łączenia pozwala na stworzenie wydajnego klasyfikatora z połączenia kilku słabych. Charakteryzuje się odpornością na przetrenowanie[13].

Przy głosowaniu (*ang.* voting) kilka klasyfikatorów samodzielnie dokonuje przydzielenia danych wejściowych do odpowiedniej klasy. Klasa wynikowa zostaje wyłoniona na drodze głosowania, to jest zostaje nią klasa, która została wyłoniona najczęściej razy podczas samodzielnych klasyfikacji.

Nakładanie (*ang.* stacking) wykorzystuje dwa poziomy klasyfikatorów. Pierwszy, tak zwany poziom 0, klasyfikuje dane wejściowe do odpowiednich klas. Wyjścia klasyfikatorów poziomu 0 są połączone z wejściami klasyfikatora poziomu wyższego, zwanego poziomem 1, który podejmuje ostateczną decyzję dotyczącą przynależności do danej klasy[19].

Połączone klasyfikatory uzyskują lepsze rezultaty. Ich połączenie obniża wariancję oraz błąd klasyfikacji[19].

1.4. Przegląd potencjalnych zastosowań


1.4.1. Interfejs komunikacyjny

Najprostsze interfejsy komunikacyjne można zrealizować dając użytkownikowi do wyboru dwie opcje: *tak* lub *nie*. Podejście dwuwartościowe pozwala na stosowanie różnorodnych technik akwizycji wyboru, między innymi poprzez analizę mrugnięć, ruchu gałek ocznych, czy sygnałów pochodzących z BCI. Przy tak skonstruowanym interfejsie osoba z niego korzystająca jest w stanie odpowiadać na pytania rozmówcy.

Taki sposób komunikacji może być zmodyfikowany w celu umożliwienia osobie użytkującej interfejs nadawania toku rozmowy. Dzięki zastosowaniu tablicy ze znakami, jej rozmówca może przemieszczać po kolei swój palec po literach alfabetu i notować te, dla których osoba korzystająca z interfejsu zakomunikowała odpowiedź *tak*. Wadą takiego rozwiązania jest fakt, iż rozmówca musi asystować osobie niepełnosprawnej, co może wprowadzać uczestników rozmowy w zakłopotanie. Taki interfejs charakteryzuje się małą stopą błędów, jednak komunikacja przy jego użyciu jest długotrwała i wynosi około jedno słowo na minutę[13].

Innym podejściem jest stworzenie systemu opartego o wirtualny kursor, który pozwoliłby użytkownikowi na samodzielnie wybieranie liter lub całych wyrazów spośród dostępnych opcji. Taki system może zawierać elementy autokorekty, aby zminimalizować występujące błędy.

W literaturze można również spotkać się z systemami badającymi potencjały wymuszone. Taką metodą jest P300. W takim interfejsie użytkownik skupia swoją uwagę na literze, którą chce wybrać. Litery są samoczynnie podświetlane w losowej kolejności. 300 milisekund po podświetleniu litery, na której użytkownik systemu jest aktualnie skupiony, można zaobserwować zmianę amplitudy rejestrowanego sygnału EEG[34]. Przykładową realizację interfejsu opartego o analizę potencjału P300 pokazano na rysunku 1.2 na następnej stronie.



Rysunek 1.2. Struktura interfejsu opartego o potencjał P300

Źródło: [25]

1.4.2. Sterowanie wózkiem inwalidzkim

Osoby sparaliżowane niekiedy są w stanie sterować wózkiem inwalidzkim, używając do tego celu wydychanego powietrza, mowy lub, w przypadku częściowego paraliżu, sprawnych części ciała. Integracja z interfejsami mózg-komputer stwarza nowe możliwości dla osób, które z powodu poważniejszych schorzeń nie są w stanie skorzystać z wyżej wymienionych metod sterowania.

Kontrola wózka inwalidzkiego może odbywać się przy wykorzystaniu sterowania *nisko-* lub *wysokopoziomowego*.

Sterowanie niskopoziomowe można zrealizować przez translację sygnałów odebranych z urządzenia rejestrującego aktywność mózgu na komendy opisujące ruch wózka (*ruch do przodu, zawrót, przyspiesz*), z zastrzeżeniem, że użytkownik wydaje je w sposób bezpośredni. Ten rodzaj sterowania wymaga zamontowania czujników na wózku, które uniemożliwią wykonanie niedozwolonych manewrów, na przykład uderzenia w inną osobę lub przedmiot. Do zalet rozwiązania można zaliczyć wysoki stopień kontroli osoby użytkującej wózek nad sposobem przemieszczania oraz stosunkowo małą ilość wymaganych komend mentalnych do podstawowego sterowania. Do wad należy konieczność wydawania poleceń ruchu w sposób ciągły, co może prowadzić do znużenia użytkownika, a w konsekwencji samoczynnego *rozstrajania się* układu sterowania.

Sterowanie wysokopoziomowe polega na wydawaniu poleceń dotyczących celu ruchu (*kuchnia, łazienka*). Podejście to wiąże się z koniecznością stosowania wózków o wysokim stopniu autonomiczności. Zaletą tego rozwiązania jest odciążenie użytkownika od konieczności utrzymywania ciągłego skupienia na kierunku oraz prędkości ruchu, wyeliminowanie wpływu zakłóceń odbieranych w trakcie przemieszczania się oraz, po zapewnieniu skutecznych algorytmów i odpowiedniej ilości czujników, bezpieczniejsze poruszanie się w środowisku. Do wad zaliczyć należy większą ilość komend, które należy zdefiniować (co najmniej po jednej dla każdego pomieszczenia), mniejszą precyzję ruchu, spowodowaną odgórnym określeniem miejsca w pomieszczeniu, do którego użytkownik

chce się przemieścić oraz konieczność zdefiniowania i zmapowania każdego środowiska, w którym będzie poruszał się wózek.

Mimo obiecujących wstępnych rezultatów, wykorzystanie interfejsów mózg–komputer do zadania sterowania wózkami inwalidzkimi jest trudne do zrealizowania z powodu braku niezawodnych, przenośnych i łatwych w użyciu urządzeń rejestrujących. Inną przeszkodą jest brak wózków o wystarczającym stopniu autonomiczności, które byłyby zdalne do pracy w codziennym środowisku[34].

1.4.3. Rehabilitacja

Można wyróżnić trzy główne sposoby wsparcia rehabilitacji medycznej przez interfejsy mózg–komputer[6]:

mózg–akcja — polega na nauczaniu pacjenta przy pomocy BCI wydawania odpowiednich poleceń, wymaganych do usprawnienia motoryki kończyn,

mózg–kończyna — polega na wykorzystaniu BCI do kontroli urządzenia wspierającego poruszanie się, a w konsekwencji odbudowania połączeń potrzebnych do poruszania się bez niego,

mózg–mózg — na podstawie informacji odebranych z systemu BCI następuje stymulacja mózgu w celu poprawy jego aktywności, aż do osiągnięcia zadowalających rezultatów.

Należy nadmienić, iż te sposoby nie wykluczają się wzajemnie – ich połączenie pozwala na zwiększenie znaczenia BCI w tej dziedzinie nauki.

Interfejsy mózg–komputer, poprzez stopniową integrację z neurorehabilitacją, mogą pomóc między innymi osobom dotkniętym udarem mózgu, który często powoduje długotrwałą niepełnosprawność ruchową oraz zaburzenia funkcji poznawczych. Wiele badań wykazuje, iż technika nieinwazyjnej stymulacji mózgu jest skuteczna, nawet w przypadku przewlekłego uszkodzenia mózgu[6]. Duża ilość osób rokrocznie dotykanych udarem stanowi badania w tym zakresie niezwykle istotnymi dla społeczeństwa.

Stosowanie BCI do wspomagania leczenia funkcji poznawczych wymaga skrupulatnej identyfikacji sygnałów mózgowych, które są możliwe do uzyskania. Może to być trudne, ponieważ nie wszystkie stany mózgu są tak dobrze scharakteryzowane, jak te związane z funkcjami motorycznymi[20].


1.4.4. Nadzór skupienia

Wykorzystanie interfejsów mózg–komputer do nadzorowania skupienia użytkownika jest szczególnie istotne w asystowaniu pracownikom wykonujących monotonne prace, takie jak prowadzenie samochodu czy monitorowanie systemu zabezpieczeń. Popęśnienie błędu w przypadku takich profesji powoduje nie tylko ryzyko dla samego pracownika, ale również dla innych osób znajdujących się w jego otoczeniu. Wiele wypadków jest spowodowanych zmęczeniem, nieuwagą lub nawet zaśnięciem podczas wykonywania pracy.

Choć znużenie lub senność może być wykryta przez analizowanie obszaru okolic oczu, taka detekcja może mieć miejsce za późno, aby było możliwe zapobiegnięcie wypadkowi. Integracja BCI z urządzeniami do nadzoru niesie możliwość wykrywania takich sytuacji, zanim doprowadzą do katastrofalnych w skutkach wydarzeń.

W związku z postępującą automatyzacją pojazdów, kierowca jest odciążany od wykonywania żmudnych zadań, takich jak utrzymywanie stałej prędkości czy przełączanie między światłami mijania oraz drogowymi. Wraz z dalszym progresem coraz więcej czynności wykonywanych jest przez sam samochód, podczas kiedy rola osoby znajdującej się w fotelu kierowcy sprowadza się do nadzoru i reagowania w niebezpiecznych sytuacjach. Może to prowadzić, w szczególności na trasach o znacznej długości, do sytuacji nadmiernej zaufania do systemu sterowania, w której to kierowca przestanie zwracać uwagę na działania pojazdu. Interfejs mózg–komputer mógłby w tym momencie sygnalizować spadek skupienia kierowcy lub wymuszać bezpieczny postój pojazdu do momentu, w którym kierujący pojazdem będzie w stanie kontynuować podróż.

Badania przeprowadzone przez naukowców z *Berlin BCI* wykazały, iż istnieje zależność pomiędzy spadkiem koncentracji, a wzrostem mocy w paśmie α ⁶[2]. Badanie polegało na sklasyfikowaniu 2000 bagaży jako bezpiecznych lub niebezpiecznych na podstawie ich prześwietleń. Wykonano je w 10 turach po 200 bagaży. Na podstawie rysunku 1.3 można wywnioskować, iż spadek koncentracji (wzrost parametru CII) prowadził do wzmożenia ilości popełnianych błędów. Uczestnicy rzeczzonego badania na okres następujący bezpośrednio po przerwie wykazywali znacznie niższy stopień błęd. Tę zależność można wykorzystać do określenia momentów, w których pracownik powinien udać się na przerwę lub, w przypadku długotrwałej niskiej koncentracji, zakończyć swoją zmianę.



Rysunek 1.3. Zależność pomiędzy stopniem skupienia CII (*ang.* concentration insufficiency index), a stopą błęd. Pionowe linie po zakończeniu dwustupróbkowych bloków oznaczają moment przerwy.

Źródło: [2]

⁶Pasmo α - pasmo fal elektromagnetycznych o częstotliwości 8÷12 Hz i amplitudzie w zakresie 20÷80 μV [20, str. 17].

1.4.5. Gry komputerowe

Wprowadzenie dedykowanych rozwiązań dla przemysłu gier komputerowych wydaje się być kolejnym krokiem po rozwoju aplikacji korzystających z technologii VR⁷ oraz AR⁸. To, co sprawia, że gracze są odpowiednim odbiorcą wczesnych systemów BCI jest fakt, iż często są oni zainteresowani nowymi technologiami, są skłonni do jej wdrażania w celu uzyskania przewagi nad przeciwnikami oraz przyzwyczajeni do konieczności treningu, który pozwala na progres w grach[24]. W związku z dynamicznym rozwojem tej branży, opracowanie rozwiązań wykorzystujących BCI może być bardzo opłacalne w przyszłości.

Wykorzystanie BCI w grach komputerowych pozwala na integrację gry z wrażeniami użytkownika. Dostarczenie informacji na temat skupienia, zainteresowania, frustracji czy znudzenia umożliwia grze dostosowanie się do potrzeb gracza. W przypadku narastania frustracji gra może samoczynnie obniżyć poziom trudności, a w przypadku znudzenia – podwyższyć. Wykorzystując inne odczucia gra może również uprościć interfejs użytkownika, czy też wyświetlić lub ukryć podpowiedzi dotyczące aktualnie wykonywanego zadania (*ang.* quest). Dynamiczne dostosowywanie gry do aktualnego stanu gracza pozwala jej na zapewnienie użytkownikowi zwiększonego komfortu podczas rozgrywki.

Innym zastosowaniem interfejsów mózg–komputer jest wydawanie poleceń za pomocą komend mentalnych. Poleceniem może być na przykład wyobrażenie sobie ruchu postaci, co prowadziłoby do faktycznego przemieszczania się kontrolowanego bohatera, czy wybieranie odpowiedzi w dialogach występujących w grze. Wiąże się to z całkowitą zależnością gry od sygnałów otrzymywanych z urządzenia rejestrującego i wnosi konieczność znacznej modyfikacji istniejących silników gier.

Zintegrowanie BCI z grami komputerowymi wiąże się nie tylko ze znacznymi inwestycjami ze strony producentów gier, ale również samych graczy, którzy będą musieli zakupić urządzenia rejestrujące aktywność mózgu. Należy zwrócić uwagę na fakt, że rozgrywki często prowadzone są przez długi okres, a więc wymogiem stawianym przed systemami rejestrującymi jest ich wygoda. Nie mogą one ograniczać ruchów użytkownika ani jego pola widzenia. Wadą rozwiązania jest fakt, iż gracze często generują napięcia mięśniowe, co będzie prowadziło do powstawania artefaktów w przypadku urządzeń rejestrujących sygnały EEG. Rozwiązaniem tego problemu może być ulepszenie algorytmów filtracji sygnałów lub stosowanie systemów hybrydowych EEG/EMG, a więc rejestrujących oraz wykorzystujących aktywność zarówno mózgu, jak i mięśni[34].

⁷VR (*ang.* virtual reality) – rzeczywistość wirtualna

⁸AR (*ang.* augmented reality) – rzeczywistość rozszerzona

ROZDZIAŁ 2

Charakterystyka wybranych urządzeń komercyjnych

2.1. Emotiv Insight

Insight (patrz rysunek 2.1 na następnej stronie) jest produktem wprowadzonym na rynek w roku 2015 przez firmę Emotiv przy wsparciu crowdfundingu na portalu kickstarter. Jest produktem do użytku codziennego, głównie za sprawą minimalistycznego designu oraz braku konieczności stosowania żelów przewodzących, przeznaczonym do mniej precyzyjnych zastosowań.

Jest wyposażony w pięć czujników właściwych oraz dwa referencyjne. Lokalizacja czujników została przedstawiona na rysunku 2.2 na stronie 21. Czas ubrania oraz ustawienia urządzenia oscyluje w granicach 1–2 minut. Parametry urządzenia zostały zestawione w tabeli 2.1.

Koszt produktu na dzień 21 kwietnia 2019 roku wynosi 299\$.

Tabela 2.1. Parametry Emotiv Insight

Źródło: Opracowanie własne na podstawie [12]

Ilość kanałów	5 (+2 referencyjne)
Umieszczenie elektrod	AF3, AF4, T7, T8, Pz
Czujniki referencyjne	DMS/DRL
Rodzaj czujników	Półsuchy polimer
Rozdzielczość	14 bit na kanał
Rozdzielczość LSB	0,51 μ V @ 14 bit
Detekcja ruchu	9-osiowy czujnik (3x żyroskop, 3x akcelerometr, 3x magnetometr)
Łączność	Bezprzewodowa 2,4GHz/Bluetooth 4.0
Zasilanie	Li-Pol 480 mAh, do 8 godzin pracy



Rysunek 2.1. Helm Emotiv Insight

Źródło: [10]

Firma Emotiv dostarcza do swoich rozwiązań API¹ o nazwie Cortex. Stanowi on podstawę do budowania aplikacji wykorzystujących pobrane z hełmów strumienie danych dzięki wykorzystaniu JSON oraz WebSocket[8]. Cortex ułatwia tworzenie gier, aplikacji oraz rejestrowania danych do późniejszego ich wykorzystania do badań.

Cortex jest wrapperem SDK² firmy EMOTIV. Zapewnia on, w zależności od rodzaju zakupionej licencji, dostęp do różnych strumieni danych z hełmów. Jest kompatybilny z systemami Mac OS oraz Windows. Umożliwia programowanie w językach Java, C#, C++, Python, Ruby, JavaScript (Node.js) oraz PHP.


Licencja Cortex jest dostępna w trzech planach:

Darmowa

- Mental Commands API,
- Performance Metrics API (do 0,1 Hz),
- Frequency Bands API,
- Facial Expressions API,
- Motion data API,

¹API (*ang.* application programming interface) – Interfejs programistyczny aplikacji. Zawiera zestaw reguł i ich opisów, które definiują sposób komunikacji między programami komputerowymi.

²SDK (*ang.* software development kit) – Zestaw narzędzi dla programistów niezbędny w tworzeniu aplikacji korzystających z danej biblioteki.



Rysunek 2.2. Rozmieszczenie sensorów w hełmie Emotiv Insight

Źródło: [10]

- nielimitowana ilość sesji na 3 urządzeniach.

Niekomercyjna pro – \$55-99/miesiąc

- Wszystkie API z licencji darmowej,
- Raw EEG API,
- oprogramowanie EmotivPRO,
- nielimitowana ilość sesji na 3 urządzeniach.

Komercyjna

- Performance Metrics API o wysokiej rozdzielczości,
- konfigurowanie API pod swoje potrzeby,
- tworzenie komercyjnych rozwiązań.

Oprogramowanie EmotivPRO[11], dostępne w licencjach niekomercyjnej pro oraz komercyjnej, stanowi wsparcie dla badań wykorzystujących EEG. Pozwala ono na akwizycję oraz prezentację strumieni danych w czasie zbliżonym do rzeczywistego, zapisywanie sesji w chmurze oraz szybką analizę wbudowanym algorytmem FFT³, bez konieczności eksportu danych.

³FFT (ang. Fast Fourier Transform) – Szybka transformacja Fouriera.

2.2. Emotiv EPOC+

EPOC+, pokazany na rysunku 2.3, został wprowadzony na rynek w 2013 roku przez firmę Emotiv. Został zaprojektowany do badań wykorzystujących EEG oraz zaawansowanych zastosowań BCI[9].

Jest wyposażony w 14 kanałów właściwych oraz 2 referencyjne (dokładna lokalizacja sensorów została przedstawiona na rysunku 2.4 na następnej stronie). W odróżnieniu od Emotiv Insight, omówionego w rozdziale 2.1 na stronie 19, wymaga stosowania *mokrych* elektrod, pokrytych nasączonym solą fizjologiczną filcem. Ze względu na większą ilość czujników niż w Emotiv Insight, czas ubrania oraz przygotowania urządzenia do pracy wynosi około 3–5 minut. Parametry hełmu zostały przedstawione w tabeli 2.2 na stronie 24.

Koszt produktu na dzień 21 kwietnia 2019 roku wynosi 799\$.



Rysunek 2.3. Hełm Emotiv EPOC+


Źródło: [9]

Od strony programistycznej urządzenie wykorzystuje to samo API oraz SDK co Emotiv Insight; zostały one omówione w rozdziale 2.1 na stronie 19.

2.3. Muse/Muse 2

Muse/Muse 2 są urządzeniami wspomagającymi medytację, które pozwalają na rejestrację w czasie rzeczywistym aktywności mózgu, tętna, oddechu oraz ruchu ciała⁴[15]. Prze-

⁴Rejestracja poszczególnych parametrów w zależności od wersji opaski.



Rysunek 2.4. Rozmieszczenie sensorów w hełmie Emotiv EPOC+

Źródło: [9]

kształcącą one zmierzoną aktywność mózgu w predefiniowane dźwięki, takie jak szum wody czy deszczu; w zależności od poziomu skupienia dźwięk będzie spokojny lub gwałtowny, co pozwala osobom uczącym się medytować na efektywniejszą naukę wyciszenia umysłu.

Oba urządzenia są z wyglądu bardzo do siebie podobne. Nowsze, Muse 2 (pokazane na rysunku 2.5 na następnej stronie), w odniesieniu do poprzedniej wersji, zostało odchudzone, przez co nabrało bardziej eleganckiego wyglądu oraz zyskało niższy profil z dodatkowymi czujnikami[18]. Dodano również miękkie w dotyku wykończenie.

Obie opaski są wyposażone w 7 czujników, w tym 3 referencyjne (patrz rysunek 2.6 na stronie 25). Zestawienie parametrów oferowanych przez obie opaski znajduje się w tabeli 2.3 na stronie 26.

Koszt Muse wynosi 219€; Muse 2 – 269€.

Muse posiada oferty skierowane do następujących grup:

Deweloperów – na dzień 23 kwietnia 2019 roku Muse nie wspiera aktywnie swojego SDK⁵. Ostatnią dostępną wersją jest v6.0.3, wydana w marcu 2018 roku. Opaska Muse 2, z racji późniejszej daty premiery, **nie jest wspierana przez SDK**. Na stronie dla deweloperów[16] znajduje się odnośnik do innych narzędzi, takich jak Muse Direct czy projektów open source, np. MuseLSL, EEG Notebooks.

Profesjonalistów – w ramach subskrypcji Muse Connect profesjonaliści otrzymują pro-

⁵SDK – Patrz przyp. 2 na stronie 20.

Tabela 2.2. Parametry Emotiv EPOC+

Źródło: Opracowanie własne na podstawie [12]

Ilość kanałów	14 (+2 referencyjne)
Umieszczenie elektrod	AF3, AF4, F3, F4, FC5, FC6, F7, F8, T7, T8, P7, P8, O1, O2
Czujniki referencyjne	DMS/DRL
Rodzaj czujników	Nasączone solą fizjologiczną
Rozdzielczość	14/16 bit na kanał
Rozdzielczość LSB	0,51 μ V @ 14 bit/0,13 μ V @ 16 bit
Detekcja ruchu	9-osiowy czujnik (3x żyroskop, 3x akcelerometr, 3x magnetometr)
Łączność	Bezprzewodowa 2,4GHz/Bluetooth 4.0
Zasilanie	Li-Pol 680 mAh, do 12 godzin pracy



Rysunek 2.5. Opaska Muse 2

Źródło: [15]


gram wspomagający rozwój ich biznesu poprzez uczenie ich klientów technik medytacji[17]. W ten sposób otrzymują dostęp do różnych wskazówek m.in. webinarów⁶, studiów przypadków oraz informacji, które pomogą wprowadzić Muse do ich biznesu. Muse Connect wspomaga prowadzenie podopiecznych: ustalanie dla nich celów do realizacji oraz śledzenie ich progresu (również w czasie rzeczywistym).

Aplikacja oferuje dwa rodzaje subskrypcji:

1. miesięczną w cenie 39\$/miesiąc,
2. roczną w cenie 33\$/miesiąc; w tej opcji dodatkowo otrzymujemy za darmo urządzenie Muse.

Naukowców – w ramach narzędzi dla naukowców Muse oferuje dostęp do MusePlayer oraz MuseLab. MusePlayer służy do rejestrowania, ponownego odtwarzania, przekierowywania oraz przetwarzania danych z opasek. Umożliwia konwersję z natyw-

⁶Webinarium – Internetowe seminarium realizowane przy wykorzystaniu streamingu wideo.



Rysunek 2.6. Rozmieszczenie sensorów w opasce Muse

Źródło: [35]

nego typu danych (.muse) na inne (.txt, .mat, .csv). MuseLab wykorzystuje się do wizualizacji danych.

2.4. MindWave Mobile 2

MindWave Mobile 2 zbudowane jest z opaski na głowę, klipsu na ucho oraz ramienia z zamocowanym czujnikiem (patrz rysunek 2.7 na stronie 27). Elektrody referencyjne oraz uziemiające znajdują się na klipsie na uchu, a elektroda EEG na ramieniu dotykającym czoła w pozycji FP1. Umożliwia pomiar sygnałów EEG, sygnałów *NeuroSky eSense*, na które składają się skupienie oraz medytacja, oraz mrugnięć. Do zasilania wykorzystywana jest pojedyncza bateria AAA, która starcza na 8 godzin pracy[21].

Parametry urządzenia zostały zestawione w tabeli 2.4 na następnej stronie.

Koszt urządzenia na dzień 25 czerwca 2019 roku wynosi 100\$.

NeuroSky dostarcza swoje API dla systemów iOS, Android, macOS oraz Windows. Darmowe narzędzia dla deweloperów składają się z trzech osobnych API[22]:

ThinkGear Connector (TGC) – program działający w tle systemu operacyjnego; zarządza komunikacją z hełmem przy pomocy TCP/IP.

ThinkGear Communication Driver (TGCD) – biblioteka zawierająca funkcje pozwalające na połączenie oraz przetwarzanie danych z hełmu. Można ją wykorzystywać z językami C/C++, Java oraz C#.

Tabela 2.3. Parametry Muse oraz Muse 2

Źródło: Opracowanie własne na podstawie [14] oraz [35]

Parametr	Muse	Muse 2
Ilość kanałów	4 (+ 3 referencyjne)	4 (+3 referencyjne)
Umieszczenie elektrod	TP9, AF7, AF8, TP10 ^a	TP9, AF7, AF8, TP10 ^a
Czujniki referencyjne	CMS/DRL	CMS/DRL
Rodzaj czujników	Suche srebrne/silikonowe	Suche srebrne/silikonowe
Rozdzielczość	12 bit na próbkę	12 bit na próbkę
Rejestrowane parametry	EEG	EEG, tętno, ruch ciała, oddech
Kompatybilność	iOS, Android	iOS, Android
Łączność	Bezprzewodowa Bluetooth 4.0	Bezprzewodowa Bluetooth 5.0
Zasilanie	Li-Ion, do 5 godzin pracy	Li-Ion, do 5 godzin pracy

^a Dokładna lokalizacja zależy od wielkości głowy użytkownika; zamieszczono lokalizację zgodną z [35].
W literaturze można spotkać również T9, FP1, FP2, T10[1].

Tabela 2.4. Parametry MindWave Mobile 2

Źródło: Opracowanie własne na podstawie [21]

Ilość kanałów	1
Umieszczenie elektrod	FP1
Czujniki referencyjne	<i>brak danych</i>
Rodzaj czujników	<i>brak danych</i>
Rozdzielczość	12 bit
Częstotliwość próbkowania	512 Hz
Detekcja ruchu	Brak
Łączność	Bezprzewodowa Bluetooth (BT/BLE)
Zasilanie	1,5 V (1 bateria AAA), do 8 godzin pracy

Protokół komunikacji MindSet – zawiera specyfikację protokołu komunikacyjnego; pozwala na integrację hełmu z dowolną platformą/językiem programowania.

Dodatkowo można wykupić narzędzia dla naukowców w cenie 500\$, na które składają się[23]:

NeuroView – aplikacja do wyświetlania oraz zapisywania danych EEG w czasie rzeczywistym. Pozwala na rejestrację czystego sygnału EEG, jego poszczególnych składowych oraz odczytów *NeuroSky eSense* dla skupienia oraz medytacji. Umożliwia eksport do plików CSV.

NeuroSkyLab – aplikacja zapewniająca integrację ze środowiskiem MATLAB.

2.5. OpenBCI Ultracortex Mark IV

Ultracortex, pokazany na rysunku 2.8 na stronie 28, jest open source'owym hełmem zaprojektowanym do pracy ze wszystkimi układami OpenBCI[32]. Pozwala na rejestrację



Rysunek 2.7. Hełm MindWave Mobile 2

Źródło: [21]

sygnałów EEG, EMG oraz ECG. Wspiera do 16 kanałów rozmieszczonych na 35 różnych lokalizacjach według systemu 10-20⁷.

W projekcie zastosowano *suche* sensory EEG. Ich rozmieszczenie pokazano na rysunku 2.9 na stronie 29.


Czas założenia oraz uruchomienia hełmu wynosi poniżej 30 sekund.

Produkt można kupić w trzech wariantach:

1. Do samodzielnego druku — dostarczane są wszystkie części hełmu oprócz tych, które można wydrukować na drukarce 3D. Hełm należy zmontować samodzielnie na podstawie dokumentacji. Cena: 300–400\$.
2. Niezmontowany — dostarczane są wszystkie części hełmu, również z tymi, które można wydrukować na drukarce 3D. Hełm należy zmontować samodzielnie na podstawie dokumentacji. Cena: 500–600\$.
3. Zmontowany — dostarczany jest całkowicie zmontowany hełm. Cena: 700–850\$.

Dodatkowo należy zakupić wybraną płytkę OpenBCI. Poniżej zamieszczono związane opisy dostępnych układów. Parametry hełmu *Mark IV* w połączeniu z kompatybilnymi płytkami zamieszczono w tabeli 2.5 na stronie 31.

⁷System 10-20 – system opisu umiejscowienia elektrod; składa się z 21 elektrod. Podstawą tego standardu jest zdefiniowanie konturów między punktami orientacyjnymi czaszki (np. nasion, inion), a następnie podzielenie ich na proporcjonalne odległości 20% całkowitej długości. Istnieją również systemy pokrewne, np. 10-10 oraz 10-5, które używają odpowiednio 10% oraz 5% całkowitej długości[37, rozdz. 6].



Rysunek 2.8. Hełm Ultracortex Mark IV

Źródło: [31]

Ganglion Board – Ganglion (patrz rysunek 2.10 na stronie 30) posiada 4 kanały, które mogą być użyte do mierzenia sygnałów EMG, EKG lub EEG[29]. Częstotliwość próbkowania wynosi 200 Hz.

Komunikacja bezprzewodowa jest realizowana z wykorzystaniem Simblee BLE, modułu Bluetooth 4.0 kompatybilnego z Arduino, który pozwala na łatwą integrację z IoT⁸. Moduł umieszczony na płytce Ganglion jest zaprogramowany i gotowy do pracy, jednak część jego wyprowadzeń pozostaje dostępna dla użytkownika do celów własnych.


Koszt układu to 200\$.

Cyton Board – Cyton, pokazany na rysunku 2.11 na stronie 30, jest kompatybilny z Arduino, posiada 8 kanałów oraz 32-bitowy procesor[28]. Podobnie jak Ganglion, może być wykorzystany do mierzenia aktywności mięśni, serca lub mózgu. Dane próbkowane są z częstotliwością 250 Hz.

Do komunikacji bezprzewodowej wykorzystywany jest moduł RFduino. Komunikacja z komputerem może być realizowana przy pomocy adaptera OpenBCI USB lub, jeżeli komputer posiada tę opcję, wbudowanego modułu BLE⁹.

⁸IoT (ang. Internet of Things) – Internet rzeczy. Koncepcja zgodnie z którą urządzenia mogą komunikować się ze sobą, wykorzystując do tego celu internet.

⁹BLE (ang. Bluetooth Low Energy) – technologia sieci bezprzewodowej o poborze mocy niższym niż w konwencjonalnych modułach Bluetooth.



Rysunek 2.9. Rozmieszczenie sensorów w hełmie Ultracortex Mark IV
Źródło: [32]

Koszt płytki to 500\$.

Cyton + Daisy Board – Ten układ zawiera opisaną wcześniej płytkę Cyton oraz Daisy, która jest *wpinana* w płytkę Cyton. Układ pokazano na rysunku 2.12 na stronie 31.

Daisy zapewnia dodatkowe 8 kanałów, które mogą być użyte do mierzenia EMG, EKG lub EEG[27]. Częstotliwość próbkowania wynosi 250 Hz.

Koszt układu to 950 \$. Płytkę Daisy nie może być zakupiona oddzielnie.


Oprogramowanie OpenBCI jest open source'owe i jest dostępne na ich profilu na GitHubie.

Głównym narzędziem do wizualizacji, nagrywania oraz komunikacji z płytkami jest OpenBCI GUI[30]. Narzędzie jest kompatybilne z systemami macOS, Windows oraz Linux. Pozwala na filtrowanie oraz przetwarzanie danych w czasie rzeczywistym. Dodatkowo pozwala na przekierowywanie danych wykorzystując protokoły UDP, OSC, LSL oraz port szeregowy.

Do komunikacji z płytkami używane są OpenBCI Ganglion SDK oraz OpenBCI Cyton SDK. Wykorzystują one protokół oparty na znakach ASCII¹⁰.


OpenBCI dostarcza również bibliotekę Brainflow, która służy do analizy danych EMG, EKG oraz EEG[26]. Została ona napisana w języku C/C++, jednak zawiera nakładki na

¹⁰ASCII (*ang.* American Standard Code for Information Interchange) – siedmiobitowy system służący do kodowania znaków.



Rysunek 2.10. OpenBCI Ganglion Board

Źródło: [29]




Rysunek 2.11. OpenBCI Cyton Board

Źródło: [28]

języki Python, Java, R, C++¹¹, Matlab oraz C#.

Platforma OpenBCI umożliwia również współpracę z innymi programami do analizy sygnałów, m.in. MATLAB, Neuromore, OpenVIBE, LabStreamingLayer oraz BrainBay.

¹¹Pomimo, że sama biblioteka napisana jest w C/C++, dodano nakładkę na język C++ w celu zapewnienia wysokopoziomowej warstwy abstrakcji.



Rysunek 2.12. OpenBCI Cyton + Daisy Board

Źródło: [27]

Tabela 2.5. Parametry Ultracortex Mark IV w połączeniu z kompatybilnymi układami

Źródło: Opracowanie własne na podstawie [32], [29],[28] oraz [27]

Parametr	Ganglion	Cyton	Cyton + Daisy
Ilość kanałów	4	8	16
Umieszczenie elektrod	Konfigurowalne ^a	Konfigurowalne ^a	Konfigurowalne ^a
Rodzaj czujników	Suche	Suche	Suche
Rozdzielczość	24 bit	24 bit	24 bit
Częstotliwość próbkowania	200 Hz	250 Hz	250 Hz
Rejestrowane parametry	EMG, EKG, EEG ^b	EMG, EKG, EEG ^b	EMG, EKG, EEG ^b
Detekcja ruchu	3 osiowy akcelerometr	3 osiowy akcelerometr	3 osiowy akcelerometr
Kompatybilność	macOS, Windows, Linux	macOS, Windows, Linux	macOS, Windows, Linu
Łączność	BLE 4.0 przez adapter	BLE	BLE
Zasilanie	6V (4 baterie AA)	6V (4 baterie AA)	6V (4 baterie AA)

^a Mark IV wspiera 35 lokalizacji według standardu 10-20. Punkty w których można umieścić elektrody pokazano rysunku 2.9 na stronie 29.

^b Sensory nie są dołączane do płytek i należy je zakupić oddzielnie.

ROZDZIAŁ 3

Projekt systemu

ROZDZIAŁ 4

Badania opracowanego systemu

4.1. Badanie wpływu zakłóceń

4.2. Badanie wpływu parametrów algorytmu

Zakończenie

TODO

Bibliografia

- [1] Bashivan P., Rish I., Heisig S.: Mental state recognition via wearable EEG. *CoRR*, t. abs/1602.00985, 2016, URL: <http://arxiv.org/abs/1602.00985>.
- [2] Blankertz B. i in.: The Berlin Brain-Computer Interface: Non-Medical Uses of BCI Technology. *Frontiers in Neuroscience*, t. 4, s. 198, 2010, DOI: 10.3389/fnins.2010.00198.
- [3] Cegielska A., Olszewski M.: Nieinwazyjny interfejs mózg-komputer do zastosowań technicznych. *Pomiary Automatyka Robotyka*, t. R. 19, nr 3, s. 5–14, 2015.
- [4] Clerc, M., Bougrain, L. i Lotte, F., red.: *Brain-Computer Interfaces 1: Foundations and Methods*, John Wiley & Sons, Inc., Hoboken, NJ, USA, lip. 2016, DOI: 10.1002/9781119144977.
- [5] Clerc, M., Bougrain, L. i Lotte, F., red.: *Brain-Computer Interfaces 2: Technology and Applications*, John Wiley & Sons, Inc., Hoboken, NJ, USA, sierp. 2016, DOI: 10.1002/9781119332428.
- [6] Coyle, D., red.: *Brain-Computer Interfaces: Lab Experiments to Real-World Applications*, Elsevier, Netherlands, 2016.
- [7] Dhiman R., Saini J., Mittal A.: Artifact removal from EEG recordings – An overview, *National Conference on Computational Instrumentation NCCI-2010*, s. 62–66, Chandigarh, India, mar. 2010.
- [8] Emotiv: *Develop with Emotiv*, URL: <https://www.emotiv.com/developer/> (dostęp: 08.04.2019).
- [9] Emotiv: *Emotiv EPOC+ 14 Channel Mobile EEG*, URL: <https://www.emotiv.com/product/emotiv-epoc-14-channel-mobile-eeeg/> (dostęp: 21.04.2019).
- [10] Emotiv: *Emotiv Insight 5 Channel Mobile EEG*, URL: <https://www.emotiv.com/product/emotiv-insight-5-channel-mobile-eeeg/> (dostęp: 21.04.2019).
- [11] Emotiv: *Emotiv PRO*, URL: <https://www.emotiv.com/emotivpro/> (dostęp: 08.04.2019).
- [12] Emotiv: *Headsets comparison chart*, URL: <https://www.emotiv.com/comparison/> (dostęp: 04.04.2019).
- [13] Hassanien, A. E. i Azar, A. T., red.: *Brain-Computer Interfaces: Current Trends and Applications*, Springer International Publishing, 2015, DOI: 10.1007/978-3-319-10978-7.
- [14] InteraXon Inc. *Compare Muse Devices*, URL: <https://choosemuse.com/product-comparison/> (dostęp: 23.04.2019).
- [15] InteraXon Inc. *Introducing Muse 2*, URL: <https://choosemuse.com/muse-2/> (dostęp: 23.04.2019).

- [16] InteraXon Inc. *Muse developer*, URL: <https://choosemuse.com/development/> (dostęp: 23.04.2019).
- [17] InteraXon Inc. *Muse professional*, URL: <https://choosemuse.com/muse-professionals/> (dostęp: 23.04.2019).
- [18] InteraXon Inc. *What are the differences between Muse 2 and Muse the brain sensing headband?*, URL: <https://choosemuse.force.com/s/article/How-is-Muse-2-different-than-Muse-the-brain-sensing-headband?> (dostęp: 23.04.2019).
- [19] Lotte F., Congedo M., Lécuyer A., Lamarche F., Arnaldi B.: A review of classification algorithms for EEG-based brain-computer interfaces. *Journal of Neural Engineering*, t. 4, no. 2, R1-R13, sty. 2007, DOI: 10.1088/1741-2560/4/2/r01.
- [20] Nam C. S., Nijholt A., Lotte F.: *Brain-Computer Interfaces Handbook: Technological and Theoretical Advances*, CRC Press, Inc., Boca Raton, FL, USA, 2018.
- [21] NeuroSky, Inc. *MindWave Mobile 2 - Brainwave Sensing Headset*, URL: <https://store.neurosky.com/pages/mindwave> (dostęp: 24.04.2019).
- [22] NeuroSky, Inc. *NeuroSky Developer*, URL: <http://developer.neurosky.com/docs/doku.php> (dostęp: 24.04.2019).
- [23] NeuroSky, Inc. *NeuroSky Research Tools*, URL: <https://store.neurosky.com/products/mindset-research-tools> (dostęp: 24.04.2019).
- [24] Nijholt A.: BCI for Games: A 'State of the Art' Survey, *Entertainment Computing - ICEC 2008*, s. 225-228, Springer Berlin Heidelberg, Berlin, Heidelberg, 2009.
- [25] Onishi A., Natsume K.: Overlapped Partitioning for Ensemble Classifiers of P300-Based Brain-Computer Interfaces. *PLOS ONE*, t. 9, no. 4, kw. 2014, DOI: 10.1371/journal.pone.0093045.
- [26] OpenBCI: *Brainflow*, URL: <https://github.com/OpenBCI/brainflow> (dostęp: 04.06.2019).
- [27] OpenBCI: *Cyton + Daisy Biosensing Boards (16-channels)*, URL: <https://shop.openbci.com/collections/frontpage/products/cyton-daisy-biosensing-boards-16-channel> (dostęp: 29.04.2019).
- [28] OpenBCI: *Cyton Biosensing Board (8-channels)*, URL: <https://shop.openbci.com/collections/frontpage/products/cyton-biosensing-board-8-channel> (dostęp: 29.04.2019).
- [29] OpenBCI: *Ganglion Board (4-channels)*, URL: <https://shop.openbci.com/collections/frontpage/products/pre-order-ganglion-board> (dostęp: 29.04.2019).
- [30] OpenBCI: *The OpenBCI GUI*, URL: https://github.com/OpenBCI/OpenBCI_GUI (dostęp: 04.06.2019).
- [31] OpenBCI: *Ultracortex Mark IV*, URL: <https://docs.openbci.com/Headware/01-Ultracortex-Mark-IV> (dostęp: 28.04.2019).

- [32] OpenBCI: *Ultracortex Mark IV EEG Headset*, URL: <https://shop.openbci.com/products/ultracortex-mark-iv> (dostęp: 28.04.2019).
- [33] Paszkiel S.: Wykorzystanie metody PCA i ICA do analizy sygnału EEG w kontekście usuwania zakłóceń. *Pomiary Automatyka Kontrola*, t. R. 59, nr 3, s. 204–207, 2013.
- [34] Rao R. P.: *Brain-Computer Interfacing: An Introduction*, Cambridge University Press, New York, NY, USA, 2013.
- [35] *Technical specifications, validation, and research use*, InteraXon Inc., kw. 2017.
- [36] Vaibhav G.: *Brain-Computer Interfacing for Assistive Robotics*, Academic Press, San Diego, 2015, DOI: 10.1016/C2013-0-23408-5.
- [37] Wolpaw J., Wolpaw E.: *Brain-Computer Interfaces: Principles and Practice*, Oxford University Press, USA, 2012.

Spis tabel

2.1. Parametry Emotiv Insight	19
2.2. Parametry Emotiv EPOC+	24
2.3. Parametry Muse oraz Muse 2	26
2.4. Parametry MindWave Mobile 2	26
2.5. Parametry Ultracortex <i>Mark IV</i> w połączeniu z kompatybilnymi układami	31

Spis rysunków

1.1. Rodzaje artefaktów występujących w sygnałach EEG	11
1.2. Struktura interfejsu opartego o potencjał P300	15
1.3. Zależność pomiędzy stopniem skupienia CII (<i>ang.</i> concentration insufficiency index), a stopą błędu. Pionowe linie po zakończeniu dwustupniowych bloków oznaczają moment przerwy.	17
2.1. Hełm Emotiv Insight	20
2.2. Rozmieszczenie sensorów w hełmie Emotiv Insight	21
2.3. Hełm Emotiv EPOC+	22
2.4. Rozmieszczenie sensorów w hełmie Emotiv EPOC+	23
2.5. Opaska Muse 2	24
2.6. Rozmieszczenie sensorów w opasce Muse	25
2.7. Hełm MindWave Mobile 2	27
2.8. Hełm Ultracortex <i>Mark IV</i>	28
2.9. Rozmieszczenie sensorów w hełmie Ultracortex Mark IV	29
2.10. OpenBCI Ganglion Board	30
2.11. OpenBCI Cyton Board	30
2.12. OpenBCI Cyton + Daisy Board	31

Spis kodów źródłowych